



پردیس علوم
دانشکده ریاضی، آمار و علوم کامپیوتر

تشخیص تشنج صرع با استفاده از یادگیری عمیق بر روی سیگنال‌های EEG

نگارنده

کیمیا اسماعیلی

استاد راهنما: باقر باباعلی

پایان‌نامه برای دریافت درجه کارشناسی
در رشته علوم کامپیوتر

تیر ۱۴۰۲

چکیده

«صرع» یک بیماری جدی مغزی است که در سراسر جهان به عنوان یک اختلال عصبی دوره‌ای شناخته می‌شود. این بیماری، نتیجه‌ی بالینی تخلیه غیرطبیعی نورولوژیکی مغز است. صرع یکی از شایع‌ترین اختلالات اصلی مغز و تشنج‌های صرعی نشانه‌ها و علائم مثبت رایج اختلال مغزی هستند. علل عمده صرع شامل علل عروقی، علل تروماتیک، عفونت‌ها و آبسه‌های مغزی، تومورهای مغزی، کمبودهای تغذیه‌ای، کمبود پیریدوکسین، اختلالات متابولیسم کلسیم، و غیره هستند. برای تشخیص صرع، نیاز به تحقیقاتی برای بهتر درک مکانیسم‌هایی که منجر به اختلالات صرعی می‌شوند، وجود دارد. ارزیابی و درمان اختلالات نوروفیزیولوژیک با استفاده از الکتروانسفالوگرام (EEG) تشخیص داده می‌شود. EEG برای طبقه‌بندی دقیق انواع مختلف صرع بسیار حائز اهمیت است و می‌تواند اطلاعات مهمی در جهت تشخیص حملات صرع، به ما ارائه کند.

هدف این پژوهش، کمک به تشخیص صرع با استفاده هوش مصنوعی^۱ است. بدین منظور، کارآمدترین روش‌های یادگیری ماشین^۲ و یادگیری عمیق^۳ بر روی داده‌های الکتروانسفالوگرافی^۴ اجرا می‌شود. ابتدا تعدادی از روش‌های یادگیر ماشین بررسی می‌شوند، سپس روش‌هایی از یادگیری عمیق را هم بر روی دادگان^۵ مناسبی اجرا می‌کنیم تا به بهترین نتایج دست یابیم.

کلمات کلیدی

هوش مصنوعی، یادگیری ماشین، یادگیری عمیق، صرع، تشنج، الکتروانسفالوگرافی، آسیب مغزی

¹Artificial Intelligence

²Machine Learning

³Deep Learning

⁴electroencephalography

⁵Dataset

سپاسگزاری

با تشکر از استاد راهنمای عزیز، جناب آقای دکتر باباعلی که با نظرات سازنده و دقیق‌شان به پیشبرد این پروژه کمک کردند.

پیشگفتار

«صرع» عبارت است از مجموعه‌ای از اختلالات عصبی مزمن پزشکی یا بلند مدت که با علامت تشنج مشخص می‌شود. این تشنجه‌ها ممکن است بسیار خفیف و تقریباً غیرقابل شناسایی بوده یا برعکس طولانی‌مدت و با لرزش شدید همراه باشد [۱۵]. در صرع تشنجه‌ها به‌طور مکرر روی می‌دهد و هیچ دلیل ثابت و مشخصی ندارد، در حالی که تشنجه‌هایی را که به دلایل خاص روی می‌دهد، نباید به عنوان تشنج صرعی تلقی کرد [۷]. صرع در واقع تنها یک بیماری نیست بلکه یک نشانه بیماری است که می‌تواند بر اثر اختلالات متعددی به وجود آید [۱۹]. حملات صرع نامشخص است؛ اما صرع در برخی افراد به دلیل آسیب مغزی، سرطان مغز، و سوء مصرف دارو و الکل، و دلایل دیگر ایجاد می‌شود. پس می‌توان از حملات صرع برای تشخیص مشکلات و درگیری‌های دیگر مغزی که صرع صرفاً نشانه آنهاست، استفاده کرد و تشخیص حملات صرع به‌طور هدفمند، برای جلوگیری و شناخت مشکلات عمیق‌تر دارای اهمیت است. در بیشتر موارد دلیل وقوع تشنجه‌های صرعی نتیجه فعالیت سلولی بیش از حد و غیرعادی عصب کورتیکال یا غشایی در مغز است. فرایند تشخیص معمولاً شامل حذف تمام شرایطی است که ممکن است علائم مشابهی نظیر سنکوپ را ایجاد کند، و نیز بررسی اینکه آیا هیچ دلیل لحظه‌ای دیگری وجود داشته‌است یا خیر. صرع را می‌توان با گرفتن نوار مغزی یا الکتروانسفالوگرافی (EEG) نیز تأیید کرد. این روش، بهترین روش^۶ برای تشخیص و نظارت حملات صرع است [۷]. با توجه به اهمیتی که در بالا ذکر کردیم، تشخیص دقیق صرع می‌تواند از مشکلات عدیده‌ای جلوگیری کند. بررسی نوار مغزی به صورت انسانی می‌تواند کار سخت و زمان‌بری باشد؛ همچنین امکان خطای انسانی در آن وجود دارد. با دانستن این موضوع، بهترین راه برای نظارت و بررسی نوار مغزی EEG، استفاده از تکنولوژی و بالاخص، روش‌هایی مانند یادگیری ماشین و یادگیری عمیق است که عملاً کار انسانی را با دقت و سرعت بالاتر، اکثراً عاری از معایب آن، شبیه‌سازی می‌کند. در این پژوهش ما قصد داریم با دقت مناسبی روش‌های گفته‌شده را اجرا کرده و نتایج بهینه‌تری برای تشخیص حملات صرع از روی داده‌های ضبط‌شده، ارائه دهیم.

^۶Standard Gold

فهرست مطالب

۱	مقدمه	۱
۱	۱.۱ ماهیت حملات صرع	۱.۱
۲	۱.۱.۱ پس از تشنج	۱.۱.۱
۲	۲.۱.۱ عوامل و نشانه‌ها	۲.۱.۱
۳	۳.۱.۱ چگونگی و مکانیسم	۳.۱.۱
۴	۲.۱ تشخیص	۲.۱
۴	۱.۲.۱ تعریف	۱.۲.۱
۴	۲.۲.۱ طبقه‌بندی	۲.۲.۱
۴	۳.۲.۱ تست‌های آزمایشگاهی	۳.۲.۱
۵	۴.۲.۱ تصویربرداری	۴.۲.۱
۵	۵.۲.۱ الکتروانسفالوگرافی	۵.۲.۱
۵	۶.۲.۱ تشخیص افتراقی	۶.۲.۱
۶	۳.۱ الکتروانسفالوگرافی	۳.۱
۶	۱.۳.۱ چگونگی اجرا	۱.۳.۱
۷	۲.۳.۱ در صرع	۲.۳.۱
۸	۲ مفاهیم مقدماتی	۲
۸	۱.۲ یادگیری تحت نظارت	۱.۲
۹	۲.۲ آموزش گروهی	۲.۲
۱۰	۳.۲ پرسپترون‌های چندلایه	۳.۲
۱۲	۴.۲ شبکه عصبی پیچشی	۴.۲
۱۴	۳ دادگان	۳
۱۴	۱.۳ The Epileptologie Database	۱.۳
۱۹	۲.۳ UPenn and Mayo Clinic's Seizure Detection Challenge	۲.۳
۲۱	۳.۳ CHB-MIT Scalp EEG Database	۳.۳
۲۵	۴.۳ NEDC TUH EEG پیکره تشنج	۴.۳

۲۸	آزمایش‌ها و نتیجه‌ها	۴
۲۸	پیش‌پردازش و مهندسی ویژگی‌ها	۱۰۴
۳۱	ارزیابی مدل و تنظیم فرایارامتر	۲۰۴
۳۷	کاهش ابعاد	۳۰۴
۳۸	یادگیری تحت نظارت	۴۰۴
۴۵	یادگیری گروهی	۵۰۴
۴۷	پرسپترون چندلایه	۶۰۴
۵۰	شبکه عصبی پیچشی	۷۰۴
۵۳	مقایسه نتایج با کارهای قبلی	۸۰۴
۵۴	جمع‌بندی	۵

فهرست تصاویر

۱۵	داده‌های اینتراکتال	۱.۳
۱۶	داده‌های اکتال	۲.۳
۱۶	داده‌های تصادفی منطقه صرعی در حالت اینتراکتال	۳.۳
۱۷	داده‌های تصادفی نیمکره مقابل در حالت اینتراکتال	۴.۳
۱۷	داده‌های تصادفی منطقه صرعی در حالت اکتال	۵.۳
۱۸	داده‌های تصادفی سطح مغز در حالت باز بودن چشم‌ها	۶.۳
۱۸	داده‌های تصادفی سطح مغز در حالت بسته بودن چشم‌ها	۷.۳
۱۹	داده‌های خام این دادگان	۸.۳
۲۰	داده‌ها در حالت اینتراکتال و اکتال	۹.۳
۲۲	داده‌های خام این دادگان	۱۰.۳
۲۳	ترسیم داده‌ها	۱۱.۳
۲۴	جایگاه سنسورها [۲۲]	۱۲.۳
۲۵	داده‌های خام این دادگان	۱۳.۳
۲۶	ترسیم داده‌ها	۱۴.۳
۲۷	جایگاه سنسورها [۲۲]	۱۵.۳
۳۱	ماتریس سردرگمی برای استخراج معیارهای دقت	۱.۴
۳۴	منحنی ROC اعتبارسنجی متقاطع	۲.۴
۳۵	منحنی دقت اعتبارسنجی متقاطع	۳.۴
۳۷	یک منحنی اعتبارسنجی برای مثال	۴.۴
۳۸	طبقه‌بندی به وسیله رگرسیون لجستیک	۵.۴
۴۰	عملکرد درخت تصمیم‌گیری	۶.۴
۴۱	طبقه‌بندی به وسیله روش کا-نزدیک‌ترین همسایه‌ها	۷.۴
۴۱	ماتریس سردرگمی برای رگرسیون لجستیک و SVM	۸.۴
۴۲	ماتریس سردرگمی برای درخت تصمیم‌گیری و KNN	۹.۴
۴۳	منحنی ROC برای روش‌های تحت نظارت	۱۰.۴
۴۳	منحنی دقت-فراخوانی برای رگرسیون لجستیک و SVM	۱۱.۴

۴۴	عملکرد SVM برحسب درستی و دقت	۱۲.۴
۴۴	پیاده‌سازی soft majority voting بر ۳ روش اول نظارتی	۱۳.۴
۴۵	عملکرد تقویت گرادیان	۱۴.۴
۴۸	ارزیابی مدل توسط تابع زیان و درستی	۱۵.۴
۴۹	ارزیابی مدل توسط تابع فراخوانی و دقت	۱۶.۴
۵۱	ارزیابی مدل توسط تابع زیان و درستی	۱۷.۴
۵۲	ارزیابی مدل توسط تابع فراخوانی و دقت	۱۸.۴
۵۳	ارزیابی مدل استفاده شده در مقاله مرجع	۱۹.۴

فصل ۱

مقدمه

۱.۱ ماهیت حملات صرع

صرع اغلب با تمایل به داشتن حملات بی‌دلیل و مکرر شناخته می‌شود. حملات صرع اغلب همراه با اختلال در آگاهی همراه هستند که نشانه‌ای از برون‌ریزش نورونی غیرطبیعی (برای مثال بیش از حد) است، که یا به طور گسترده یا موضعی وجود دارند. بیش از ۴۰ نوع صرع و بیش از ۴۰ نوع حمله مختلف وجود دارد که افراد ممکن است انواع متعددی را تجربه کنند. علائم بالینی صرع وابسته به چندین عامل هستند؛ مانند سندرم خاص صرع، سن بیماران، منطقه مغزی که حملات را تولید می‌کند و اینکه برون‌ریزش به طور موضعی باقی می‌ماند یا به سایر مناطق مغز گسترش می‌یابد [۷].

شایع‌ترین نوع تشنج‌ها (۶۰٪ موارد) تشنج حرکتی است [۱۹]. از این دسته، دو سوم به صورت تشنج صرعی موضعی ظاهر می‌شوند که بعداً به تشنج منتشر تبدیل می‌شوند در حالی که یک سوم به صورت تشنج منتشر اولیه ظاهر می‌شود. ۴۰٪ تشنج‌های باقی‌مانده غیر حرکتی هستند. یک نمونه از این نوع تشنج ابسانس است که به صورت سطح پایین هوشیاری روی می‌دهد و معمولاً ۱۰ ثانیه طول می‌کشد [۵].

تشنج‌های موضعی اغلب بعد از برخی تجربیات مشخص روی می‌دهد که با عنوان اورا شناخته می‌شوند. این تجربیات ممکن است شامل پدیده‌های حسی (دیداری، شنیداری یا بویایی)، روانی، ارادی، یا حرکتی باشد [۱۹]. پرس ممکن است در یک گروه ماهیچه‌ای خاص شروع شده و به گروه‌های ماهیچه‌ای اطراف گسترش یابد که در این مورد با عنوان مارش جکسون شناخته می‌شود. حرکت غیرارادی نیز ممکن است روی دهد؛ که منظور از آن فعالیت‌های غیرارادی و حرکت‌های اغلب ساده‌ای نظیر ملچ ملوچ لب‌ها یا فعالیت‌های پیچیده‌تری نظیر تلاش برای برداشتن چیزی است [۵].

شش نوع مهم حمله عمومی وجود دارد: صرع همراه با تشنج، تونیک، صرع تونیک، همراه با تشنج، تنش ماهیچه‌ای، پریشانی، و تشنج‌های ضعیف. تمامی این تشنج‌ها شامل از دست رفتن هوشیاری بوده و معمولاً بدون علامت هشدار روی می‌دهند. حملات کششی-ارتجاعی همراه با انقباض اندام‌ها و

سپس کشیدگی آن‌ها و قوس هم‌زمان کمر است که ۱۰ تا ۳۰ ثانیه طول می‌کشد (فاز تونیک). شاید در اثر انقباض ماهیچه‌های سینه صدای یک فریاد شنیده شود. سپس لرزش هماهنگ اندام‌ها روی می‌دهد (فاز کلونیک). حملات کششی انقباضات یکنواخت ماهیچه‌ها را موجب می‌شوند. فرد معمولاً هنگامی که تنفسش قطع می‌شود، کی‌بود می‌شود. در تشنج‌های کلونیک لرزش یکنواخت اندام روی می‌دهد. پس از اینکه لرزش متوقف شد، ۱۰ تا ۳۰ دقیقه طول می‌کشد تا فرد به حالت عادی برگردد. این دوره فاز پس از تشنج نام دارد [۵].

از دست دادن کنترل روده یا مثانه شاید در طول تشنج روی دهد. نوک یا گوشه‌های زبان ممکن است در طول حمله گاز گرفته شود. در تشنج تونیک-کلونیک گاز گرفتن لبه‌های زبان رایج تر است. گاز گرفتن زبان همچنین در تشنج‌های سایکولوژیک غیرصرعی نیز رایج است [۱۹].

حملات ماهیچه‌ای شامل گرفتگی ماهیچه‌ها در برخی یا در همه نواحی است. حملات پریشانی می‌توانند نامحسوس بوده و فقط شامل گردش ملایم سر یا چشمک زدن چشم‌ها باشند. فرد نمی‌افتد و پس از پایان این دوره به حالت عادی بازمی‌گردد. حملات ضعیف شامل از دست دادن فعالیت ماهیچه برای مدت بیش از یک ثانیه است. این مورد در هر دو طرف بدن روی می‌دهد [۵].

حدود ۶٪ از افرادی که صرع دارند حملاتی دارند که با رویدادهای خاصی تحریک می‌شوند و به حمله انعکاسی معروف هستند. افراد مبتلا به صرع انعکاسی حملاتی دارند که تنها با محرک‌های خاصی تحریک می‌شوند. محرک‌های معمول شامل درخشش چراغ و صداهای ناگهانی است. در انواع خاصی از صرع، حملات اغلب در طول خواب روی می‌دهند. و در دیگر انواع آن، حملات تنها در خواب روی می‌دهند [۱۹].

۱۰.۱.۱ پس از تشنج

پس از بخش فعال حمله، معمولاً دوره‌ای از گیجی وجود دارد که با عنوان دوره پس از حمله شناخته می‌شود که پیش از بازگشت سطح هوشیاری عادی است. این دوره معمولاً ۳ تا ۱۵ دقیقه طول می‌کشد اما شاید تا چهار ساعت هم طول بکشد. افراد اغلب به خاطر نمی‌آورند در این مدت زمان چه اتفاقی افتاده است. ضعف موضعی، که با نام فلج تاد شناخته می‌شود، نیز ممکن است در یک حمله موضعی روی دهد. وقتی این حمله روی می‌دهد، معمولاً از چند ثانیه تا چند دقیقه طول می‌کشد، اما به ندرت یک یا دو روز ادامه دارد [۵].

۲۰.۱.۱ عوامل و نشانه‌ها

صرع در واقع تنها یک بیماری نیست بلکه یک نشانه بیماری است که می‌تواند بر اثر اختلالات متعددی به وجود آید. فلذا تشخیص حملات صرع به طور هدفمند، برای جلوگیری و شناخت مشکلات عمقی‌تر دارای اهمیت است. تشنج‌ها خود به خود و بدون علت خاصی مانند بیماری شدید اتفاق می‌افتند. علت اصلی رخ دادن صرع می‌تواند عوامل ژنتیکی یا مشکلات ساختاری یا متابولیک باشد، این در حالی است

که در ۶۰٪ موارد، علت آن نامشخص است. شرایط بیماری ژنتیکی، بیماری مادرزادی و اختلال رشد در افراد جوان شایع است، این در حالی است که تومور مغزی و سکنه مغزی در افراد مسن رایج است. تشنج‌ها همچنین می‌توانند بر اثر مشکلات بهداشتی دیگر رخ دهند؛ اگر آن‌ها به علت خاصی مانند سکنه، صدمه به سر، خوردن مواد سمی یا مشکلات متابولیک رخ دهند، به جای صرع به آن‌ها تشنج علامتی حاد گفته می‌شود و در دسته‌بندی بالاتر اختلالات مرتبط با تشنج قرار می‌گیرند. اکثر عوامل تشنج علامتی حاد باعث به وجود آمدن تشنج‌های بعدی می‌شوند که به آن‌ها صرع ثانویه گفته می‌شود [۲۳]. چندین نشانه صرع وجود دارد که بر اساس سن شروع گروه‌بندی می‌شوند: دوره نوزادی، کودکی، بزرگسالی و موارد بدون ارتباط سنی چشمگیر. علاوه بر این، گروه‌هایی وجود دارد که دارای ترکیبی از این نشانه‌ها هستند، برخی از این نشانه‌ها بر اثر دلایل ساختاری با متابولیک خاص و برخی بدون هیچ دلیل خاصی هستند. توانایی محققان در گروه‌بندی یک نوع صرع به سندرم‌های خاص بیشتر در رابطه با کودکان اتفاق می‌افتد. برخی از انواع آن عبارت است از: صرع رولاندیک خوش خیم (۲.۸ در هر ۱۰۰۰۰۰ نفر)، صرع غایب دوران کودکی (۰.۸ در هر ۱۰۰۰۰۰ نفر) و صرع میوکلونیک نوجوانی (۰.۷ در هر ۱۰۰۰۰۰ نفر). تشنج ناشی از تب و تشنج‌های نوزادی خوش خیم صرع محسوب نمی‌شوند [۱۹].

۳.۱.۱ چگونگی و مکانیسم

به‌طور معمول فعالیت الکتریکی مغز هم‌زمان اتفاق نمی‌افتد. در تشنج‌های صرعی، بر اثر مشکلات ساختاری یا عملکردی مغز، [۳] گروهی از نرون‌ها به‌طور غیرطبیعی، بیش از حد و هماهنگ فعالیت می‌کنند. این امر منجر به موجی از دپولاریزاسیون می‌شود که به جابجایی دپلاریزان حمله‌ای معروف است. به‌طور معمول، پس از شروع به فعالیت کردن نرون برانگیخته، برای مدتی در برابر فعالیت مقاومت می‌کند. علت آن تأثیر نرون‌های مهار، تغییرات الکتریکی در نرون برانگیخته و اثرات منفی آدنوزین می‌باشد. در صرع، مقاومت نرون‌های برانگیخته در برابر فعالیت در طول این دوره کاهش پیدا می‌کند. این امر باعث تغییر در کانال یون یا باعث عمل نکردن صحیح نرون‌های مهار می‌شود. بعد از آن، مناطق خاصی به وجود می‌آیند، که به آن‌ها «کانون تشنج» گفته می‌شود، و ممکن است باعث گسترش تشنج شوند. سازوکار دیگر صرع می‌تواند تنظیم افزایشی مدارهای تحریک یا تنظیم کاهشی مدارهای مهار بعد از ضربه به مغز باشد. این صرع‌های ثانویه در طول فرآیندی به نام روند ایجاد تشنج رخ می‌دهند. ناتوانی سد خونی مغزی نیز ممکن است یک مکانیزم علی باشد زیرا ممکن است اجازه دهد مواد از خون وارد مغز شوند. تشنج‌های فوکال در یکی از نیم‌کره مغزی هنگامی که تشنج‌های عمومی در هر دو نیم‌کره شروع می‌شود. برخی از تشنج‌ها ممکن است باعث تغییر ساختار مغز شود، این در حالی است که تشنج‌های دیگر اثر اندکی بر مغز می‌گذارند. گلیوز، خیز مغزی و فرسایش برخی از قسمت‌های مغز به صرع ربط داده می‌شود اما مشخص نیست صرع باعث این تغییرات می‌شود یا این تغییرات باعث به وجود آمدن صرع می‌شود [۳].

۲.۱ تشخیص

تشخیص صرع به طور کلی بر اساس توصیف تشنج‌ها و اتفاقات جانبی می‌باشد. الکتروانسفالوگرافی و تصویربرداری از سیستم عصبی نیز بخشی از عملیات تشخیصی است. همواره پیدا کردن سندروم صرعی خاص امکان‌پذیر نیست. تست نوار مغز طولانی مدت همراه با ویدئو نیز ممکن است در برخی موارد مفید باشد [۱۳].

۱.۲.۱ تعریف

صرع در عمل به عنوان دو یا چند تشنج صرعی تعریف می‌شود که فاصله آن‌ها ۲۴ ساعت است و دلیل خاصی ندارد؛ این درحالی است که حمله صرعی به عنوان نشانه یا عاملی تعریف می‌شود که بر اثر فعالیت الکتریکی غیرعادی مغز به وجود می‌آید. حمله صرعی همچنین می‌تواند به عنوان اختلالی در نظر گرفته شود که در آن فرد حداقل یک تشنج صرعی داشته و احتمال افزایش این تشنج‌ها وجود دارد. لیگ بین‌المللی ضد صرع و دفتر بین‌المللی صرع، همکاران سازمان بهداشت جهانی در ارزیابی سال ۲۰۰۵ خود صرع را به عنوان «اختلال مغز که به وسیله در معرض قرارگیری همیشگی در برابر به وجود آمدن تشنج‌های صرعی و پیامدهای زیست شناختی، شناختی، روانشناختی و اجتماعی این شرایط توصیف می‌شود. تعریف صرع نیازمند رخ دادن حداقل یک تشنج است [۳].»

۲.۲.۱ طبقه‌بندی

افرادی که دچار تشنج می‌شوند را می‌توان بر اساس نوع تشنج، عامل تشنج، سندرم صرع و اتفاقات رخ داده هنگام و حوالی رخ دادن صرع دسته‌بندی کرد. نوع تشنج را می‌توان بر اساس اینکه منشأ صرع درون مغز محلی (تشنج فوکال) یا توزیع شده است (تشنج کلی) طبقه‌بندی کرد. تشنج‌های کلی بر اساس تأثیر بدن طبقه‌بندی می‌شود و شامل موارد زیر است: تشنج‌های تونیک-کلونیک (صرع همراه با تشنج و علائم دیگر)، تشنج غائب (تشنج غایب صرع کوچک)، نوع تشنج، تشنج تونیک و تشنج عضلات. نوع برخی از تشنج‌ها مانند گرفتگی عضلات نامشخص است [۳].

تشنج‌های فوکال (که قبلاً به عنوان تشنج‌های منطقه‌ای شناخته می‌شدند) به تشنج‌های تشنج جزئی ساده و تشنج جزئی پیچیده تقسیم می‌شوند. این تقسیم‌بندی دیگر توصیه نمی‌شود و در عوض ترجیح داده می‌شود آنچه که طول تشنج رخ می‌دهد توصیف شود [۱۳].

۳.۲.۱ تست‌های آزمایشگاهی

در مورد افراد بالغ، آزمایش الکترولیت، قند خون و سطح کلسیم برای از بین بردن مشکلات این عوامل مهم است. گرفتن نوار قلب می‌تواند مشکلات ضربان قلب را برطرف کند. پونکسیون کمری می‌تواند در

تشخیص عفونت دستگاه عصبی مرکزی مفید باشد اما به طور معمول مورد نیاز نیست. آزمایش های بیشتر مانند آزمایش بیوشیمی ادرار و آزمایش خون در کودکان نیاز است تا بیماری های متابولیک تشخیص داده شود. سطح پرولاکتین بالای خون در ۲۰ دقیقه اول بعد از تشنج برای تعیین اینکه تشنج صرعی یا غیر صرعی است بسیار مفید است. سطح پرولاکتین سروم خون در تشخیص تشنج های موضعی کمتر مفید واقع می شود. اگر عادی باشد، احتمال بروز تشنج غیر صرعی وجود دارد و سروم پرولاکتین تشنج های صرعی را از سنکوپ متمایز نمی کند. و بخشی از تشخیص صرع به حساب نمی آید [۵].

۴.۲.۱ تصویربرداری

تصویربرداری تشخیصی به وسیله سی تی اسکن و ام آر آی بعد از تشنج بدون تب اول توصیه می شود تا مشکلات ساختاری در اطراف و درون مغز مشخص شود. ام آر آی به طور کلی برای تصویربرداری بهتر است مگر در شرایطی که احتمال داده می شود که فرد خونریزی دارد، در این شرایط سی تی اسکن نتیجه بهتری دارد و به آسانی در دسترس است. اگر شخصی به دلیل صرع به اورژانس مراجعه کند و به سرعت به حالت طبیعی بازگردد، بهتر است تصویربرداری پس از گذشت مدتی انجام شود. اگر تصویربرداری قبلی مشخص شود شخصی دارای صرع است، حتی با وجود تشنج های بعدی دیگر نیازی به تصویربرداری مجدد نیست [۱۳].

۵.۲.۱ الکتروانسفالوگرافی

الکتروانسفالوگرافی (EEG) می تواند به نشان دادن فعالیت مغز که نشان دهنده افزایش ریسک صرع است کمک کند. این روش تنها برای افرادی توصیه می شود که تشنج صرعی بر اساس نشانه های آن را تجربه کرده اند. در تشخیص صرع، الکتروانسفالوگرافی ممکن است به تشخیص نوع تشنج یا سندروم موجود کمک کند. در کودکان تنها پس از تشنج دوم به این روش نیاز است. این روش نمی تواند به جای تشخیص استفاده شود و در مواردی ممکن است نتیجه آن برای افرادی که دچار این بیماری نیستند مثبت نشان داده شود. در برخی شرایط، هنگامی که شخص خواب است یا دچار بی خوابی است، انجام EEG بهترین نتایج را همراه دارد. در مورد این روش با جزئیات بیشتر در بخش بعدی پرداخته می شود [۳].

۶.۲.۱ تشخیص افتراقی

تشخیص صرع ممکن است دشوار باشد و تشخیص اشتباه بسیار رخ می دهد (در حدود ۵ تا ۳۰ درصد موارد). شرایط دیگر ممکن است نشانه ها و علائم مشابه صرع داشته باشند، از جمله: سنکوپ، هیپرونتیلیاسیون، میگرن، حمله خواب، وحشت زدگی و تشنج غیر صرعی روانزا (PNES). تقریباً یک پنجم افرادی که به کلینیک های صرع مراجعه می کنند دچار PNES هستند. و از این تعداد حدود ۱۰ درصد نیز صرع دارند. در اکثر موارد تفکیک این دو بر اساس حملات تشنج و بدون آزمایش بیشتر

دشوار است. کودکان ممکن است دارای رفتارهایی باشند که اشتباهاً به عنوان تشنجات صرعی در نظر گرفته می‌شوند. این رفتارها شامل: حملات ریسه، شب‌ادراری، هراس شبانه، تیک و میوکلونس می‌باشد. بازگشت اسید به مری ممکن است باعث درد در کمر شود و کژگردنی در نوزادان ممکن است اشتباهاً به جای تشنج تونیک-کلونیک تشخیص داده شود [۱۳].

۳.۱ الکتروانسفالوگرافی

نوار مغزی یا الکتروانسفالوگرافی، ثبت فعالیت الکتریکی مغز است، این تکنیک شامل اخذ سیگنال توسط الکترودهای سطحی، بهبود سیگنال (معمولاً تقویت و حذف نویز)، چاپ سیگنال و آنالیز آن می‌شود. آنچه روی کاغذ چاپ می‌شود، الکتروانسفالوگرام نامیده می‌شود. نتایج حاصل از نوار مغزی را نمی‌توان به صورت مستقیم و تنها با مشاهده سیگنال مورد بررسی و تفسیر قرار داد و از روی آن ناهنجاری را تشخیص داد. معمولاً طیف فرکانسی این سیگنال حاوی اطلاعات مفیدی است که کاربردهای تشخیصی و تحقیقاتی از جمله موارد زیر دارد:

- ۱- کمک به تشخیص و تعیین محل آسیب مغزی
- ۲- کمک به مطالعه صرع (حملات گذرای برگشت‌پذیر عمل مغز دچار مشکل با حس نامنظم و فعالیت حرکتی نظیر تشنج)
- ۳- کمک به تشخیص اختلالات روانی
- ۴- کمک به مطالعه خواب
- ۵- اجازه مشاهده و آنالیز پاسخ‌های مغز به محرک‌های سنسوری [۱۴]

۱۰.۳.۱ چگونگی اجرا

روند انجام تست بسیار آسان است. کافی است بیمار روی یک تخت دراز بکشد یا بر روی یک صندلی بنشیند تا پزشک یک کلاه حاوی الکترودها را روی سر او قرار دهد. ممکن است بجای کلاه آزمایش، یک سری الکترودهای گرد شبیه به دیسک با یک خمیر یا ژل که امکان چسبندگی برای الکترودها به وجود می‌آورد بر روی پوست سر بیمار قرار بگیرد. این الکترودها در حدود ۸ تا ۲۵ عدد هستند. روند آزمایش معمولاً خیلی طولانی نیست اما در برخی شرایط ممکن است یک الی دو ساعت زمان ببرد. در ابتدا صرفاً در شرایط آرامش، گزارش‌گیری انجام می‌شود. یعنی لازم است فرد به حالت آرام بخوابد و چشم‌های خود را بسته نگه دارد چون هرگونه حرکت می‌تواند نتیجه‌ی آزمایش را تحت‌تأثیر قرار دهد. اما ممکن است در حین آزمایش محرک‌هایی مانند نور، صدا حرکت، تنفس سریع نیز در نظر گرفته شود تا عملکرد مغز بهتر رصد شود. برای افرادی که نوار مغزی جهت بررسی اختلال خواب در آن‌ها تجویز شده است، معمولاً این تست در هنگام خواب انجام خواهد شد [۱۴].

۲۰۳۰۱ در صرع

EEG به عنوان روش تشخیصی استاندارد برای تأیید صرع مورد استفاده قرار می‌گیرد. حساسیت EEG معمولی در تشخیص تخلیه‌های غیرطبیعی در مراکز صرعی در بازه ۵۵-۲۹٪ گزارش شده‌است. با توجه به حساسیت کم تا متوسط آن، یک EEG معمولی (با مدت زمان معمولی ۲۰-۳۰ دقیقه) ممکن است در افرادی که صرع دارند، نرمال باشد. وقتی EEG نشان دهنده تخلیه‌های غیرطبیعی که منجر به صرع می‌شوند، باشد (الگوهای مانند امواج تیز و غیره در نوار مغزی)، تقریباً در تمامی موارد تأیید صرع است (با دقت بالا)، با این حال تا ۳۰.۵٪ جمعیت عمومی می‌توانند برون‌ریزش غیرطبیعی داشته باشند در صورتی که اصلاً دچار حمله نشده‌اند (نرخ منفی کاذب^۱ پایین) یا دارای شانس بسیار کم بروز صرع در آینده هستند. هنگامی که یک EEG معمولی نرمال است اما شک بالایی وجود دارد یا نیاز به تأیید صرع است، ممکن است آن را با مدت زمان بیشتر در واحد نظارت بر صرع (EMU) تکرار کنند یا در منزل با یک EEG متقاطع انجام شود. علاوه بر این، مانورهای فعالیتی مانند تحریک نوری، افزایش تنفس و خلق بی‌خوابی که می‌تواند بازده تشخیصی EEG را افزایش دهد، موجود است [۱۳].

همانطور که گفتیم، گاهی اوقات یک EEG معمولی کافی نیست تا تشخیص را قطعی کند یا بهترین روش درمانی را تعیین کند. در این موارد، تلاش‌هایی برای ضبط یک EEG هنگام بروز حمله صورت می‌گیرد. این با عنوان ضبط اکتال^۲ شناخته می‌شود که در مقابل ضبط میان‌اکتال یا اینتر اکتال^۳ است که به ضبط EEG بین حملات اشاره دارد. برای به دست آوردن ضبط، اکتال معمولاً یک EEG طولانی همراه با ضبط ویدیو و صوت همزمان انجام می‌شود. این ضبط می‌تواند به صورت خانگی و بیمارستانی در واحد نظارت بر صرع (EMU) انجام شود. در حالت خانگی، نظارت تا حدوداً ۳ روز به طول می‌انجامد اما در حالت بیمارستانی ممکن است پایش حتی بیشتر از چند هفته به طول بینجامد که در این زمان داروهای سرکوب‌کننده حملات مصرف نمی‌شوند تا بیمار شانس بیشتری برای داشتن حملات صرع ضبط آن‌ها داشته باشد. نظارت در حین حملات زمانی در نظر گرفته می‌شود که بیمار علی‌رغم مصرف داروهای سرکوب‌کننده حملات، همچنان دارای حمله و تشنج است یا در صورتی که شک بر مشکلات و تشخیص‌های افتراقی دیگر برای وضعیت بیمار وجود دارد. در حالت‌هایی که بیمار قطعاً حمله صرع دارد، این‌گونه نظارت از جهت شناخت چگونگی حملات و تشخیص ناحیه‌ای از مغز که عامل شروع حملات است، مزیت دارد. در استفاده بالینی، نوار مغزی توسط متخصصان اعصاب به صورت بصری تحلیل می‌شود تا ویژگی‌های مختلف مورد بررسی قرار بگیرند. با پیشرفت تکنولوژی، تحلیل کمی نوار مغزی همراه با تحلیل بصری استفاده می‌شود. استفاده از روش‌های تحلیل کمی از قبیل تحلیل طیف توان، نسبت آلفا-دلتا، نوار مغزی توام با شدت متغیر و شناسایی امواج تیز می‌تواند به تشخیص سریع بخش‌هایی از نوار مغزی که نیاز به تحلیل بصری دقیق‌تر دارند یا در برخی موارد، به عنوان جایگزین برای شناسایی سریع حملات صرع در ضبط‌های بلندمدت استفاده شود [۳].

¹false positive

²ictal

³inter-ictal

فصل ۲

مفاهیم مقدماتی

اصول یادگیری ماشین و یادگیری عمیق: ابتدا مفاهیم کلی‌ای که در این مقاله استفاده شده‌اند را به اختصار معرفی کرده و توضیح کوتاهی در مورد هر کدام ارائه می‌دهیم. اینجا مروری جامع از روش‌های ریاضی مورد استفاده در هوش مصنوعی (AI) ارائه کرده و مفاهیم کلیدی در یادگیری ماشین و یادگیری عمیق را بررسی می‌کنیم. مواردی مانند پیش پردازش داده‌ها و مهندسی ویژگی‌ها، یادگیری نظارت شده، ارزیابی مدل و تنظیم فرایارامتر، یادگیری مجموعه، کاهش ابعاد، پرسپترون چندلایه و شبکه عصبی پیچشی بررسی می‌شود.

۱.۲ یادگیری تحت نظارت

طبقه‌بندی‌کننده‌ها کلاس‌های از پیش تعیین‌شده را با این فرض که داده‌های ارائه‌شده متعلق به یکی از کلاس‌ها هستند، جدا می‌کنند. یک طبقه‌بندی‌کننده می‌تواند به سادگی آستانه‌ای را بر ویژگی‌ها تحمیل کند یا از روش‌های پیچیده‌تری مانند استفاده از الگوریتم‌های یادگیری ماشین استفاده کند، که نیاز به آموزش و کاربرد برای داده‌های دیده نشده دارد [۲۲]. اگر یک الگوریتم یادگیری ماشین برای طبقه‌بندی داده‌ها انتخاب شود، انتخاب ویژگی‌ها تنها اولین گام است و اغلب با انتخاب یک معیار عملکرد برای بهینه‌سازی، انتخاب یک یا چند طبقه‌بندی‌کننده و الگوریتم‌های بهینه‌سازی، ارزیابی عملکرد مدل و سپس تنظیم الگوریتم دنبال می‌شود. الگوریتم‌های یادگیری ماشینی را می‌توان بر اساس سطح «نظارت» برای یادگیری دسته‌بندی کرد. یادگیری نظارت شده جایی است که داده‌ها با استفاده از مثال‌های آموزشی بر روی برچسب‌ها نگاشت می‌شوند و بنابراین می‌توانند به عنوان یک کار طبقه‌بندی نیز شناخته شوند. «نظارت‌شده» به جایی اشاره دارد که برچسب‌های خروجی مورد نظر قبلاً شناخته شده است. طبقه‌بندی، زیرمجموعه‌ای از یادگیری تحت نظارت، با هدف پیش‌بینی کلاس برچسب‌های نمونه‌های داده جدید بر اساس مشاهدات قبلی است. طبقه‌بندی باینری جایی است که یک الگوریتم قوانینی را برای تمایز بین دو

حالت یاد می‌گیرد، با اکثر الگوریتم‌های یادگیری ماشینی می‌توان با استفاده از تکنیک‌هایی مانند روش‌های یک در مقابل استراحت یا یک در مقابل یک به طبقه‌بندی چند کلاسه تعمیم داد. علاوه بر برچسب‌های طبقه‌بندی، می‌توان نتایج مستمر را با استفاده از الگوریتم‌هایی مانند تحلیل رگرسیون پیش‌بینی کرد. دو نوع گسترده از الگوریتم طبقه‌بندی وجود دارد. الگوریتم‌های مولد و افتراقی الگوریتم‌های تولیدی، مانند مدل‌های بیزی ساده، مدل‌های پنهان مارکوف، و مدل‌های مخلوط گاوسی، احتمال مشترک نمونه‌های داده و برچسب‌های آنها را یاد می‌گیرند و متعاقباً قضیه بیز را برای محاسبه احتمال پسین و پیش‌بینی نمونه‌های داده جدید به کار می‌گیرند. قضیه بیز روشی برای انتخاب مدل با محاسبه احتمال یک مدل با توجه به داده‌ها و توزیع مورد انتظار احتمالات (قبلی) است. الگوریتم‌های افتراقی، مانند رگرسیون لجستیک، ماشین‌های بردار پشتیبان و درخت‌های تصمیم، مرزهای جداکننده برچسب‌ها را مدل‌سازی می‌کنند. به طور کلی الگوریتم‌های افتراقی از الگوریتم‌های مولد بهتر عمل می‌کنند، اما الگوریتم‌های مولد می‌توانند برچسب‌های جدید را شناسایی کنند [۱۷].

داده‌های آموزشی و آزمایشی: برای تقسیم داده‌ها از تابعی می‌نویسیم که این عملکرد به طور خودکار داده‌ها را قبل از تقسیم بر می‌زند. ما یک پارامتر را اصلاح می‌کنیم تا مولد اعداد شبه تصادفی داخلی را که برای به هم زدن مجموعه‌های داده استفاده می‌شود، اصلاح کنیم و اطمینان حاصل شود که نتایج ما قابل تکرار هستند. در برخی از کاربردهای این حوزه، داده‌ها دارای تعداد متفاوتی از داده‌ها در هر کلاس هستند. این مورد به‌ویژه در تشخیص تشنج، جایی که تشنج (اکتال) به ندرت در مقایسه با EEG اولیه (اینتراکتال - دوره بین تشنج) اتفاق می‌افتد. یادگیری و پیش‌بینی الگوریتم‌های یادگیری ماشینی متاثر از عدم تعادل است. برای مثال، تابع تصمیم یک SVM خطی ممکن است به نفع کلاس آ باشد. تعدادی روش برای رسیدگی به عدم تعادل در یک دادگان وجود دارد که انواع آن به طور کلی به زیر نمونه‌گیری، بیش از نمونه‌گیری و ترکیبی از هر دو دسته‌بندی می‌شوند. **طبقه‌بندی دودویی:** این روش شامل رگرسیون لجستیک، ماشین بردار پشتیبان، درخت تصمیم‌گیری و کا-نزدیک‌ترین همسایه‌ها است.

۲.۲ آموزش گروهی

هدف روش‌های گروهی بهبود تعمیم‌پذیری یک الگوریتم با ترکیب پیش‌بینی‌های چند تخمین‌گر است. برای دستیابی به این هدف دو روش کلی وجود دارد: میانگین‌گیری و تقویت [۱۷]. **روش‌های میانگین‌گیری:** چندین تخمین‌گر مجزا می‌سازد و سپس، همانطور که از نامشان پیداست، پیش‌بینی‌هایشان را میانگین می‌کنند. با کاهش واریانس، آنها نسبت به هر تخمین‌گر پایه منفرد بهتر عمل می‌کنند. این روش‌ها عبارتند از: طبقه‌بندی کیسه‌ای، جنگل‌های تصادفی، و رای اکثریت [۱۷] [۹]. **روش‌های تقویت:** روش‌های تقویت معمولاً تخمین‌گرهای ضعیفی هستند که به‌طور متوالی ساخته می‌شوند و هر برآوردگر تلاش می‌کند تا سوگیری و بایاس قبلی را کاهش دهد. یادگیرندگان ضعیف اغلب فقط یک مزیت عملکردی جزئی نسبت به حدس زدن تصادفی دارند، اما با تمرکز بر نمونه‌های آموزشی که طبقه‌بندی آنها دشوار است، عملکرد کلی گروه بهبود می‌یابد [۹]. در مقایسه با مدل‌های بسته‌بندی،

تقویت می‌تواند منجر به کاهش بایاس و واریانس شود، اما الگوریتم‌هایی مانند تقویت‌آدا^۱ نیز به دلیل بیش‌برازش با داده‌های آموزشی (واریانس بالا) شناخته می‌شوند.

۳.۲ پرسپترون‌های چندلایه

تا کنون ما روی چیزی تمرکز کرده‌ایم که می‌توان آن را رویکردهای یادگیری ماشینی "کم عمق" نامید، و بنابراین اکنون بر یادگیری "عمیق" تمرکز خواهیم کرد. یادگیری عمیق مجموعه‌ای از الگوریتم‌هایی است که برای آموزش کارآمد بسیاری از شبکه‌های عصبی مصنوعی لایه‌ای ایجاد شده است. آموزش شبکه‌های عصبی چندلایه نسبت به الگوریتم‌های ساده‌تر قبلی (مثلاً رگرسیون لجستیک یا ماشین‌های بردار پشتیبان) سخت‌تر است، زیرا معمولاً هزاران یا حتی میلیاردها وزن وجود دارد که باید بهینه شوند. این بدان معناست که باید اقداماتی انجام شود تا اطمینان حاصل شود که الگوریتم بهینه‌سازی در کمینگی محلی به دام نمی‌افتد [۹]. اولین معماری شبکه عصبی مصنوعی (ANN) در سال ۱۹۴۳، در مقاله‌ای که مدل محاسباتی نورون‌های بیولوژیکی را توصیف می‌کند، ارائه شد. نورون‌های بیولوژیکی از یک جسم سلولی، با یک هسته، با شاخه‌های گسترده‌ای به نام دندریت تشکیل شده‌اند. یک اروشاد طولانی به نام آکسون از بدن سلولی خارج می‌شود و دارای شاخه‌های کوچکتری در قسمت انتهایی به نام تلودندری است. که هر کدام دارای پایانه‌های سیناپسی هستند. نورون‌ها ورودی سیگنال‌های الکتریکی را از طریق سیناپس‌ها دریافت می‌کنند و اگر سیگنال‌های کافی از سایر نورون‌ها (پتانسیل عمل) دریافت کند، سیگنال خود را شلیک می‌کنند. میلیاردها نورون در شبکه‌هایی مرتب شده‌اند تا محاسبات پیچیده را محاسبه کنند. اگرچه شبکه‌های عصبی مصنوعی مدرن از الهامات بیولوژیکی خود دور شده‌اند، معماری شبکه‌های عصبی بیولوژیکی هنوز یک حوزه فعال تحقیقاتی است [۱۷]. در اینجا بررسی می‌کنیم که چگونه می‌توانیم شبکه‌های مصنوعی را برای طبقه‌بندی خروجی‌های میلیون‌ها/میلیارد نورون هنگام ضبط عادی (اینترکتال) یا همزمان برای ایجاد تشنج (ایکتال) اعمال کنیم.

پرسپترون پرسپترون یکی از ساده‌ترین معماری‌های شبکه عصبی مصنوعی مبتنی بر نورون‌های مصنوعی به نام واحد منطق آستانه (TLU) / واحد آستانه خطی (LTU) است. ورودی‌ها و خروجی‌ها عددی هستند و هر ورودی با وزنی مرتبط است. TLU مجموع وزنی ورودی‌ها را محاسبه می‌کند، تابع گام را اعمال می‌کند و نتیجه را به بیرون می‌دهد. رایج‌ترین تابع گام، تابع گام Heaviside است. یک TLU منفرد می‌تواند برای طبقه‌بندی باینری خطی ساده با محاسبه ترکیب خطی ورودی‌ها استفاده شود، و اگر این ورودی‌ها از یک آستانه فراتر رفت، یک کلاس مثبت یا منفی را خروجی می‌دهد. تمرین فقط به معنای یافتن مقادیر مناسب وزن‌ها است [۲۴]. پرسپترون یک لایه منفرد از TLU‌ها است که هر نورون به همه ورودی‌ها متصل است. عبور ویژه از نورون‌ها به نام نورون‌های ورودی، که هر ورودی تغذیه‌شده را خروجی می‌دهند، معمولاً اولین هستند. همچنین یک ویژگی سوگیری اضافی که معمولاً اضافه می‌شود نورون سوگیری وجود دارد که فقط ۱ را همیشه خروجی می‌دهد [۹]. "سلول‌هایی که با هم آتش

¹AdaBoost

می گیرند، با هم سیم می کشند^۲ سیگرید لولول این نقل قول اساساً قانون هبز است که وزن اتصال بین دو نورون زمانی افزایش می یابد که خروجی یکسانی داشته باشند. پرسپترون ها به گونه ای آموزش داده شده اند که در این قاعده، نوع دیگری داشته باشند که خطای شبکه را در نظر می گیرند، نه اتصالاتی را که منجر به خروجی اشتباه می شود، تقویت می کند. یک نمونه آموزشی در یک زمان تغذیه می شود و هر یک پیش بینی می کند. برای هر نورون خروجی که یک پیش بینی اشتباه ایجاد می کند، وزن های اتصال را که می توانست به پیش بینی صحیح کمک کند، دوباره تقویت می کند [۹].

پرسپترون ها چند محدودیت دارند. آنها شبیه به طبقه بندی کننده های رگرسیون لجستیک هستند، اما پرسپترون ها یک احتمال کلاس را خروجی نمی دهند. آنها فقط بر اساس یک آستانه سخت پیش بینی می کنند. همچنین، آنها قادر به حل برخی از مسائل بی اهمیت نیستند [۹]. با این حال برخی از این محدودیت ها را می توان با یک پرسپترون چند لایه ای حل کرد. برای این کار، تابع گام باید به یک تابع لجستیک تغییر یابد تا به کاهش گرادیان^۲ اجازه دهد تا در هر مرحله پیشرفت کند. علاوه بر تابع لجستیک (محدوده خروجی ۰ تا ۱)، پیش نمایش برگشتی ممکن است با سایر توابع فعال سازی مانند تابع مماس هذلولی (tanh) استفاده شود، که محدوده خروجی آن از -۱ تا ۱ است که به نرمال شدن خروجی هر لایه کمک می کند، و تابع رلو^۳ که پیوسته است و تغییر ناگهانی در شیب دارد. وقتی کلاس های خروجی انحصاری هستند، خروجی بعداً توسط یک تابع نرم افزار مشترک اصلاح می شود، جایی که خروجی هر نورون با احتمال تخمینی کلاس مطابقت دارد [۶].

باید لایه های مدل را تعریف کنیم. یک لایه داده ها را با در نظر گرفتن یک یا چند تانسور به عنوان ورودی پردازش می کند و یک یا چند تانسور را خروجی می کند. برخی از لایه ها بدون حالت هستند، اکثر آنها حالتی به شکل وزن لایه در یک یا چند تانسور دارند. لایه ها و معماری های مختلفی وجود دارد، مانند: لایه های پیچشی، لایه های عادی سازی پاسخ، لایه های ترکیبی، [۱۷] [۲۴]. و لایه های مکرر معماری ها و نحوه پیاده سازی: با انباشتن چندین لایه از انواع مختلف می توانید ایجاد کنید:

پرسپترون های چند لایه: لایه های کاملاً متصل

شبکه های عصبی پیچشی: لایه های کاملاً متصل، پیچشی و ادغام شونده

شبکه عصبی مکرر: لایه های مکرر و کاملاً متصل [۹]

توابع فعال سازی: توابع فعال سازی سیگنال ورودی را به سیگنال خروجی تبدیل می کند. به طور خاص، مجموع ورودی ها و وزن ها را به دست می آوریم و تابع فعال سازی $f(x)$ را برای به دست آوردن خروجی آن لایه اعمال می کنیم. بدون تابع فعال سازی، مدل فقط می تواند تبدیل های خطی داده های ورودی را یاد بگیرد. ابتدا به سه تابع فعال سازی رایج نگاه می کنیم: سیگموئید، Tanh و ReLU. سیگموئید مقادیر را به یک بازه [۰، ۱] کاهش می دهد و اغلب برای ایجاد مقداری استفاده می شود که می تواند به عنوان یک احتمال استفاده شود [۶]. ReLU (واحد خطی شده) مقادیر منفی را صفر می کند.

تابع زیان: در اینجا اندازه گیری می کنیم که خروجی مدل چقدر از آنچه انتظار داشتیم فاصله دارد. این

^۲Gradient Descent

^۳ReLU

زمانی است که ما یک «تابع زیان» (یا تابع هدف) تعریف می‌کنیم تا پیش‌بینی‌های شبکه و هدف واقعی را محاسبه کنیم و امتیازی از فاصله آنها از یکدیگر محاسبه کنیم. بهینه‌سازها: هنگامی که خروجی مدل خود را با تابع زیان خود به ثمر رساندیم، می‌خواهیم این را به اتصالات موجود در مدل بازخورد دهیم. این برای تنظیم وزن‌ها به گونه‌ای است که آنها امتیاز ضرر را برای مثال فعلی داده‌ها کاهش دهند. این تنظیم وظیفه بهینه‌ساز است که الگوریتم پس‌انتشار خطا^۴ را پیاده‌سازی می‌کند. در شروع یک مدل به وزن شبکه مقادیر تصادفی اختصاص داده می‌شود، به طوری که به طور تصادفی داده‌ها را تبدیل می‌کند. بیش از نمونه‌های متعددی که در یک حلقه تمرینی به سیستم تغذیه می‌شود، وزن‌ها کمی در جهت درست تنظیم می‌شوند تا زیان کاهش یابد. زیان را می‌توان به عنوان یک شیب در نظر گرفت، با هر تغییر پله به سمت پایین شیب. با مخالفت با انحنا و به‌روزرسانی وزنه‌ها به طوری که در جهت مخالف گرادیان حرکت می‌کنید، جایی که شیب به سمت بالا افزایش می‌یابد، به طور شهودی باید در منحنی زیان پایین‌تر باشید. روش‌های بهینه‌سازی عبارتند از: کاهش گرادیان، بهینه‌سازی مقدار حرکت، بهینه‌سازی مقدار حرکت نستروف، آداگرد^۵، آرام‌اس‌پراپ^۶ و تخمین حرکت تطبیقی^۷ [۶]. همچنین ما توابع، callback، مولد دسته، و غیره را داریم. در نرمال‌یچسازی هم نرمال‌سازی دسته‌ای و برش گرادیان را داریم. برای منظم‌سازی نیز چندین معیار وجود دارد.

۴.۲ شبکه عصبی پیچشی

شبکه‌های عصبی از مغز ما الگو گرفته‌اند. نودهایی وجود دارند که لایه‌ها را در شبکه تشکیل می‌دهند و دقیقاً مانند نورون‌های مغز ما، نواحی مختلف را به هم متصل می‌کنند. به ورودی‌های نودها در یک لایه، وزنی اختصاص می‌یابد که تأثیری را که پارامتر بر نتیجه پیش‌بینی کلی دارد، تغییر می‌دهد. از آنجا که وزن‌ها به پیوندهای بین نودها اختصاص داده می‌شوند، ممکن است هر نود تحت تأثیر وزن‌های مختلف قرار گیرد. شبکه عصبی تمام داده‌های آموزش را در لایه ورودی می‌گیرد. سپس داده‌ها را از میان لایه‌های پنهان عبور داده، مقادیر را براساس وزن هر نود تغییر می‌دهد و در نهایت مقداری را در لایه خروجی برمی‌گرداند. شبکه عصبی کانولوشن نوع خاصی از شبکه عصبی با چندین لایه است که داده‌هایی را که آرایش شبکه‌ای دارند، پردازش کرده و سپس ویژگی‌های مهم آن‌ها را استخراج می‌کند. یک مزیت بزرگ استفاده از CNN این است که نیازی به انجام پیش‌پردازش زیادی روی تصاویر نیست. در بیشتر الگوریتم‌هایی که پردازش تصویر را انجام می‌دهند، فیلترها معمولاً توسط یک مهندس بر اساس روش‌های اکتشافی^۷ ایجاد می‌شوند. CNN می‌تواند مهم‌ترین ویژگی فیلترها را بیاموزد و چون به پارامترهای زیادی احتیاج نیست، صرفه‌جویی زیادی در وقت و عملیات آزمون و خطا صورت می‌گیرد.

^۴Backpropagation

^۵AdaGrad

^۶RMSProp

^۷heuristic

هدف اصلی الگوریتم CNN این است که با حفظ ویژگی‌هایی که برای فهم آنچه داده‌ها نشان می‌دهند مهم هستند، داده‌ها را به فرم‌هایی که پردازش آن‌ها آسان‌تر است، درآورد. آن‌ها همچنین گزینه خوبی برای کار با دادگان‌های عظیم هستند. یک تفاوت بزرگ بین CNN و شبکه عصبی معمولی این است که CNN برای مدیریت ریاضیات پشت‌صحنه، از کانولوشن استفاده می‌کنند. حداقل در یک لایه از CNN، به جای ضرب ماتریس از کانولوشن استفاده می‌شود. کانولوشن‌ها تا دو تابع را می‌گیرند و یک تابع را برمی‌گردانند. با استفاده از این الگوریتم، می‌توانیم روی مسائل پیچیده‌تری مانند تشخیص چهره کار کنیم. کمبود داده یکی از مشکلاتی است که مانع استفاده از CNN می‌شود. با وجود اینکه می‌توان شبکه‌ها را با تعداد داده نسبتاً کمی (تقریباً ۱۰,۰۰۰) آموزش داد، هرچه اطلاعات بیشتری در دسترس باشد، CNN بهتر تنظیم می‌شود. فقط به خاطر داشته باشید که این داده‌ها باید بدون نقص و دارای برچسب باشند تا CNN بتواند از آن‌ها استفاده کند و این چیزی است که باعث می‌شود کار کردن با آن‌ها زمان‌بر و نیازمند منابع سنگین محاسباتی باشد [۲۴].

انواع روشهای هسته در این روش:

CNN یک بعدی: در این حالت، کرنل CNN در یک جهت حرکت می‌کند. های CNN یک بعدی معمولاً روی داده‌های سری زمانی استفاده می‌شوند. برای قسمت یک بعدی ما یک دیتافریم ۳ بعدی داریم:

- پنجره های مختلف داده (هر کدام با یک برچسب کلاس در آرایه y)
- هر نقطه داده (۵۱۲ طول پنجره است)
- کانال های مختلف

CNN دوبعدی: در این نوع از CNN کرنل‌ها در دو جهت حرکت می‌کنند. های CNN دوبعدی در برچسب‌گذاری و پردازش تصویر کاربرد دارند. عموماً روی داده های تصویر سه بعدی استفاده می‌شود. بخش دوبعدی شرحی از نحوه لغزش هسته در اروشاد داده ها است. خود کرنل در واقع سه بعدی است و داده های سه بعدی را خروجی می دهد. برای قسمت دوبعدی ما یک دیتافریم ۴ بعدی داریم:

- پنجره های مختلف داده (هر کدام با یک برچسب کلاس در آرایه y)
- سطوح UDWT
- هر نقطه داده (۵۱۲ طول پنجره است)
- کانال های مختلف

فصل ۳

دادگان

در این پژوهش با دانستن محدودیت‌ها و قابلیت‌های هر مدل و روش، از دادگان‌هایی با ویژگی‌های متفاوت استفاده شده (برای مثال برای روش‌هایی مانند CNN نیاز به دادگان بزرگتر و دقیق‌تر است).

۱.۳ The Epileptologie Database

در زیر شرح خوبی از داده‌های یکی از مقالاتی که قبلاً از این دادگان استفاده کرده است [۱] آورده شده است: «پنج مجموعه (با علامت A-E) که هر کدام شامل ۱۰۰ قطعه EEG تک کانالی با مدت زمان ۶.۲۳ ثانیه بود، برای مطالعه تشکیل شد. این بخش‌ها پس از بازرسی بصری برای عوامل تاثیرگذار بر روند طبیعی، از ضبط‌های EEG چندکانالی پیوسته انتخاب و حذف شدند. برای مثال توسط فعالیت ماهیچه‌ای یا حرکات چشم حذف شدند. علاوه بر این، بخش‌ها باید معیار ثابت بودن را (که به تفصیل در آن مقاله توضیح داده شده است) برآورده می‌کردند. مجموعه‌های A و B شامل بخش‌هایی بود که از ضبط‌های EEG سطحی که بر روی پنج داوطلب سالم با استفاده از یک طرح استاندارد قرار دادن الکتروود انجام شد، گرفته شده بود. داوطلبان در حالت بیداری با چشمان باز (A) و چشمان بسته (B) آرام بودند. مجموعه‌های C، D و E از آرشیو EEG تشخیص قبل از جراحی ما گرفته شده‌اند. برای مطالعه حاضر EEG از پنج بیمار انتخاب شد که همه آنها پس از برداشتن یکی از ساختارهای هیپوکامپ به کنترل کامل تشنج دست یافته بودند، بنابراین به درستی تشخیص داده شد که این نقطه، منطقه شروع صرع است. بخش‌های مجموعه D از داخل منطقه صرع‌زایی، و بخش‌های مجموعه C از تشکیل هیپوکامپ نیمکره مخالف مغز ثبت شدند. در حالی که مجموعه‌های C و D فقط شامل فعالیت تشنج بوده. در اینجا بخش‌هایی از تمام سایت‌های ضبط که فعالیت اکتال را نشان می‌دهند انتخاب شدند. تمام سیگنال‌های EEG با همان سیستم تقویت‌کننده ۱۲۸ کانالی، با استفاده از یک مرجع معمولی متوسط [عدم حذف الکترودهای حاوی فعالیت پاتولوژیک (C,D,E) یا حرکتی قوی چشم که غیرطبیعی بودند (A,B)] ثبت شدند. پس از

تبدیل ۱۲ بیتی آنالوگ به دیجیتال، داده ها به طور پیوسته بر روی دیسک یک سیستم کامپیوتری جمع آوری داده با نرخ نمونه برداری ۱۷۳.۶۱ هرتز نوشته شد. تنظیمات فیلتر باند گذر ۰.۵۳ تا ۴۰ هرتز بود.» این دو مقاله [۱] [۱۸] از این دادگان ها استفاده کرده اند. در اینجا داده ها را ترسیم می کنیم و به دو نمونه از فعالیت های «پایه» و «تشنج» در حالت های اکتال و اینتراکتال نگاهی می اندازیم. همچنین از هر مجموعه یا پوشه به صورت تصادفی ۹ فایل انتخاب و ترسیم می کنیم تا درک بهتری از داده داشته باشیم.


Inter-Ictal

Setting up band-pass filter from 0.53 - 40 Hz

IIR filter parameters

Butterworth bandpass zero-phase (two-pass forward and reverse) non-causal filter:

- Filter order 16 (effective, after forward-backward)
- Cutoffs at 0.53, 40.00 Hz: -6.02, -6.02 dB



شکل ۱۰.۳: داده های اینتراکتال


Ictal

Setting up band-pass filter from 0.53 - 40 Hz

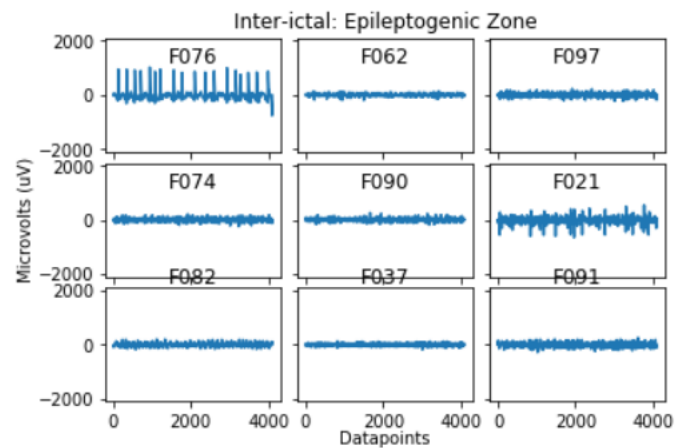
IIR filter parameters

Butterworth bandpass zero-phase (two-pass forward and reverse) non-causal filter:

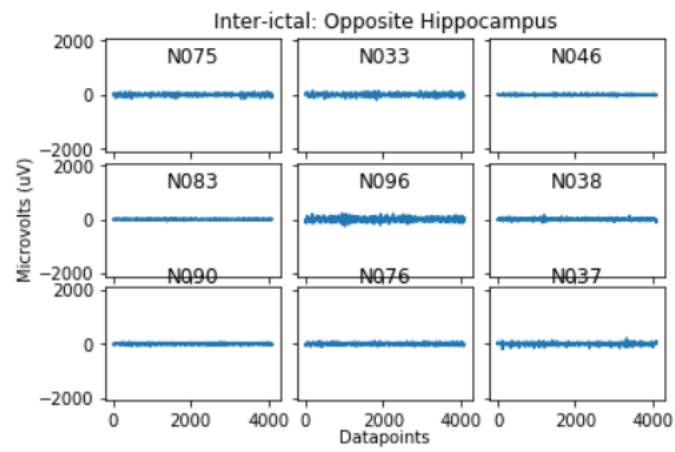
- Filter order 16 (effective, after forward-backward)
- Cutoffs at 0.53, 40.00 Hz: -6.02, -6.02 dB



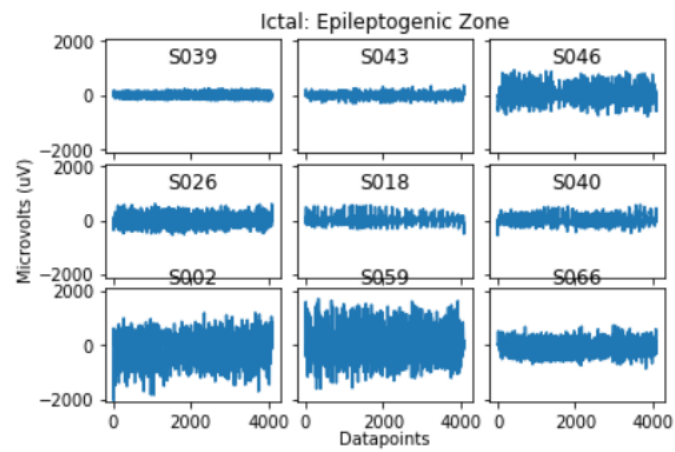
شکل ۲.۳: داده‌های اکتال



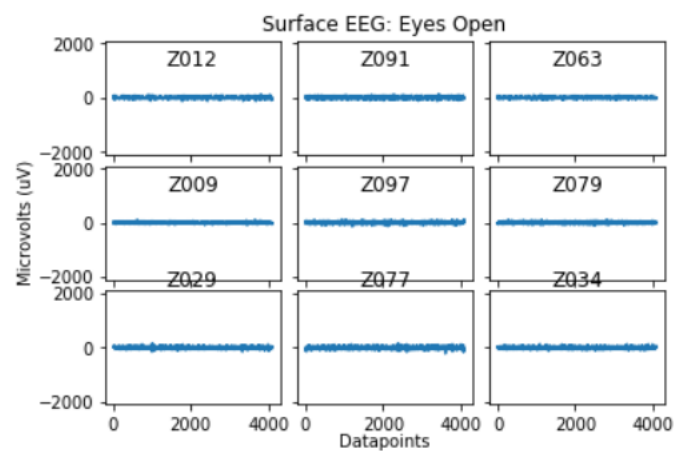
شکل ۳.۳: داده‌های تصادفی منطقه صرعی در حالت اینتراکتال



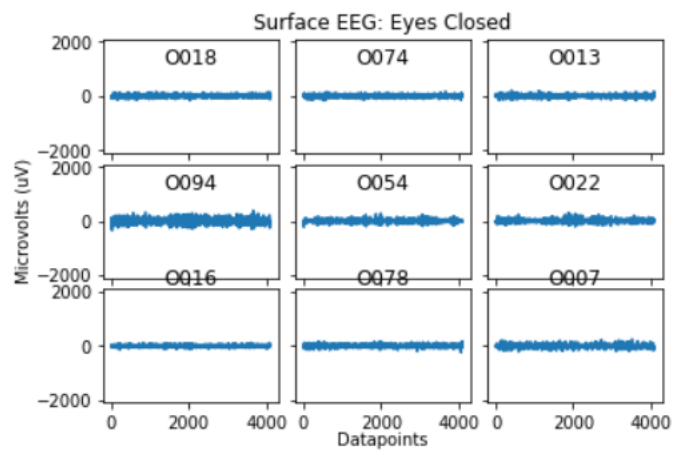
شکل ۴.۳: داده‌های تصادفی نیمکره مقابل در حالت اینتراکتال



شکل ۵.۳: داده‌های تصادفی منطقه صرعی در حالت اکتال



شکل ۶.۳: داده‌های تصادفی سطح مغز در حالت باز بودن چشم‌ها



شکل ۷.۳: داده‌های تصادفی سطح مغز در حالت بسته بودن چشم‌ها


۲.۳ UPenn and Mayo Clinic's Seizure Detection Challenge

این دادگان در ابتدا برای یک مسابقه کگل در سال ۲۰۱۴ بود. (<https://www.kaggle.com/c/seizure>). detection داده ها شامل ۱ ثانیه تشنج اکتال و اینتراکتال در ۴ سگ و ۸ بیمار انسان است [۴]. موارد ضبط شده در ۴۰۰ هرتز از ۱۶ کانال بین مجموعه ای در سگ ها و در ۵۰۰ هرتز یا ۵ کیلوهرتز از تعداد و مکان های مختلف الکترودهای بین مجموعه ای در انسان نمونه برداری شد [۲۰]. برای اطلاعات بیشتر به جدول همین صفحه مراجعه کنید. در ادامه تصاویر ترسیم شده از داده ها را نمایش می دهیم. مقالاتی که از این دادگان استفاده کرده اند آورده شده اند [۲۰] [۱۱] [۲].


Subject	Electrode No.	Ictal Length (s)	Interictal Length (s)	Unlabeled Length (s)	Train/Test ratio
Dog-1	16	178	418	3181	0.19
Dog-2	16	172	1148	2997	0.44
Dog-3	16	480	4760	4450	1.18
Dog-4	16	257	2790	3013	1.01
Patient-1	68	70	104	2050	0.08
Patient-2	16	151	2990	3894	0.81
Patient-3	55	327	714	1281	0.81
Patient-4	72	20	190	543	0.39
Patient-5	64	135	2610	2986	0.92
Patient-6	30	225	2772	2997	1
Patient-7	36	282	3239	3601	0.98
Patient-8	16	180	1710	1922	0.98
Total	-	2477	23445	32915	0.79

شکل ۸.۳: داده های خام این دادگان

Ictal



Interictal



شکل ۹.۳: داده‌ها در حالت اینتراکتال و اکتال

۳.۳ CHB-MIT Scalp EEG Database

دادگان CHB-MIT شامل سوابق ۲۳ بیمار است. با یک مورد (chb21) که از همان بیمار ۱۰۵ سال بعد گرفته شده است. این دادگان توسط محققین بیمارستان کودکان بوستون و موسسه فناوری ماساچوست (MIT) جمع آوری شد. میانگین طول جمع آوری ۳۶ ساعت با فاصله های کمی بین رکوردها در هر ساعت به دلیل محدودیت های سخت افزاری بود. داده ها شامل ۱۹۸ تشنج در انواع مختلف (تشنج کانونی، جانبی و عمومی) است. همه سیگنال ها با ۲۵۶ نمونه در ثانیه ثبت شدند و اکثر فایل ها حاوی ۲۳ سیگنال EEG بودند که با استفاده از سیستم بین المللی ۱۰-۲۰ قرار گرفتند.

این دادگان یکی از برجسته ترین مجموعه های داده در ادبیات است، زیرا ضبط های طولانی و پیوسته را برای هر بیمار فراهم می کند و امکان توسعه و آزمایش مدل های خاص و عمومی بیمار را فراهم می آورد. در شکل ۱۰.۳ نمایش داده ها و در شکل ۱۱.۳ داده ها را به صورت ترسیم شده می بینیم. حال به محل قرارگیری الکترودها توجه کنیم. این به این دلیل است که این اولین دادگان خارج مجموعه ای است (به این معنی که الکترودها در زیر پوست سر کاشته نمی شوند). EEG پوست سر معمولاً از طریق قرار دادن ۲۱-۲۵۶ الکترود Ag/AgCl روی پوست سر به دست می آید تا امکان اندازه گیری پتانسیل الکتریکی بین الکترودهای فضایی متفاوت را فراهم کند. یک الکترود به عنوان مرجع در هنگام ضبط و دیگری به عنوان زمین اختصاص داده شده است. اصطلاحات «زمین» و «مرجع» گاهی اوقات به جای یکدیگر استفاده می شوند، اگرچه آنها به فرایندهای جداگانه اشاره دارند.


الکترود زمین یک مرجع رایج برای ولتاژ سیستم است که هدف آن خنثی کردن تداخل حالت مشترک است. حالت مشترک زمانی رخ می دهد که بدن به طور طبیعی تداخل الکترومغناطیسی را می گیرد (به خصوص در حدود ۶۰/۵۰ هرتز)، مگر اینکه ضبط در قفس فارادی انجام شود. اگر قبلاً این تداخل در زمان ضبط توسط تقویت کننده انجام نشده است، اغلب باید در حین پیش پردازش فیلتر شود. الکترود زمین را می توان در هر جایی از بدن قرار داد، اگرچه پیشانی یا گوش رایج ترین آنها هستند [۲۲].

الکترود مرجع عمل حذف فعالیت غیر اختصاصی مغز با نمایش پتانسیل الکتریکی بین یک الکترود فعال دلخواه و یک مرجع نسبتاً غیرفعال را انجام می دهد. یک الکترود مرجع نیز همچنان تحت تأثیر تغییرات ولتاژ جهانی است زیرا در برابر زمین سیگنال جمع می شود. ارجاع را می توان با استفاده از یک الکترود مرجع فیزیکی قرار داده شده بر روی لاله گوش، استفاده از هر الکترود در حین ضبط و ارجاع مجدد الکترودها به میانگین خروجی همه الکترودها یا با اندازه گیری پتانسیل بین دو الکترود فعال (ضبط دوقطبی) انجام داد [۲۲]. ترکیب یک الکترود فعال با یک مرجع و یک زمین یک کانال ایجاد می کند و به پیکربندی کلی این کانال ها مونتاژ می گویند. این کانال ها در اینجا از مونتاژ دوقطبی استفاده می کنند. با داشتن نام مجموعه ها و مونتاژها، جایگاه سنسورها را در شکل ۱۲.۳ ترسیم می کنیم.



¹Massachusetts Institute of Technology

Subject	Age/Gender	Seizure Events	Total Ictal Time (secs)	Total Inter-ictal Time (secs)
chb01/chb21	11, 13 (F)	11	641	263461
chb02	11 (M)	3	172	126751
chb03	14 (F)	7	402	136366
chb04	22 (M)	4	378	561414
chb05	7 (F)	5	558	139813
chb06	1.5 (F)	10	153	240075
chb07	14.5 (F)	3	325	241044
chb08	3.5 (M)	5	919	71084
chb09	10 (F)	4	276	244043
chb10	3 (M)	7	447	179612
chb11	12 (F)	3	806	124416
chb12	2 (F)	27	989	73466
chb13	3 (F)	12	535	118232
chb14	9 (F)	8	169	93405
chb15	16 (M)	20	1992	142004
chb16	7 (F)	10	84	68297
chb17	12 (F)	3	293	75310
chb18	18 (F)	6	317	127932
chb19	19 (F)	3	236	107480
chb20	6 (F)	8	294	99043
chb22	9 (F)	3	204	111376
chb23	6 (F)	7	424	95177
chb24	NR (NR)	16	511	76134
Total	-	185	11125	3515935

شکل ۱۰.۳: داده‌های خام این دادگان



شکل ۱۱.۳: ترسیم داده‌ها



شکل ۱۲.۳: جایگاه سنسورها [۲۲]

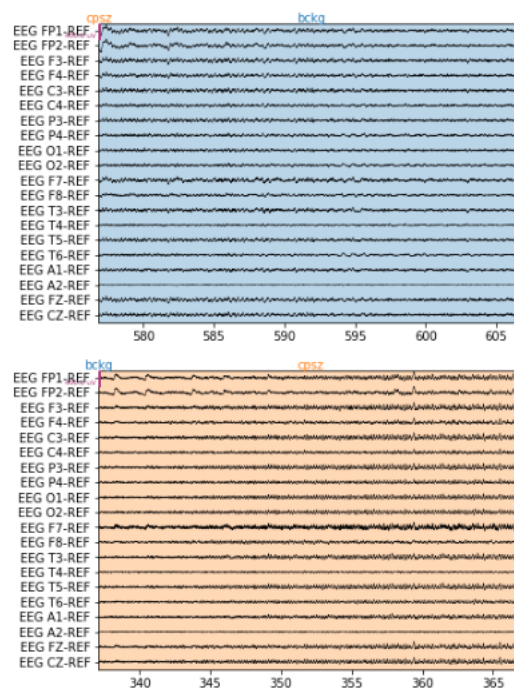
۴.۳ NEDC TUH EEG پیکره تشنج

۲ مجموعه کامل TUH بزرگترین دادگان های EEG بالینی در دسترس عموم است. مجموعه شامل ۱۵۷۵۷ ساعت ضبط EEG از ۱۳۵۳۹ بیمار است. در ادامه از زیرمجموعه‌ای از دیتاست اصلی (TUH EEG) پیکره تشنج (v1.5.0) استفاده می‌کنیم که به صورت دستی حاشیه‌نویسی شده و به مجموعه‌های آموزشی و آزمایشی و همچنین به جلسات با و بدون تشنج تقسیم شده است. مجموعه آموزشی کامل شامل ۵۹۲ بیمار است که ۲۰۲ نفر از آنها تشنج دارند که در مجموع ۲۳۷۰ تشنج در ۹ نوع طبقه بندی شده است. مدت زمان تمام تشنج ها ۴۶.۷ ساعت از کل ۷۵۲.۳ ساعت داده های EEG موجود است. داده های آزمایش نیز بزرگ است، در مجموع ۵۰ بیمار، ۳۹ بیمار با تشنج، ۶۸۵ تشنج (۱۶.۹۵ ساعت) و ۱۷۰.۳۴ ساعت داده است. سیگنال ها معمولاً در پیکربندی کانال ۱۰/۲۰ ضبط و برای هر جلسه، الکترودها یا به مونتاژ متوسط یا متصل گوش‌ها ارجاع می‌شوند [۲۲]. در شکل‌های زیر به ترتیب داده‌ها، ترسیم آنها و (مانند دادگان قبلی) جایگاه سنسورهای ضبط را می‌بینیم.



Class No.	Event Name	Signs	Locality	Description
Class Code				
NaN	No Event	NaN	NaN	An unclassified event
SPSW	1 Spike/Sharp and Wave	Electrographic	All	Spike and wave/complexes , sharp and wave/comp...
GPED	2 Generalized Periodic Epileptiform Discharges	Electrographic	Generalized	Diffused periodic discharges
PLED	3 Periodic Lateralized Epileptiform Discharges	Electrographic	Hemispheric/Focal	Focal periodic discharges
EYBL	4 Eye blink	Clinical & Electrographic	Focal	A specific type of sharp, high amplitude eye m...
ARTF	5 Artifacts (All)	Clinical & Electrographic	All	Any non-brain activity electrical signal, such...
BCKG	6 Background	Electrographic	NaN	Baseline/non-interesting events
SEIZ	7 Seizure	Clinical & Electrographic	All	Common seizure class which can include all typ...
FNSZ	8 Focal Non-Specific Seizure	Electrographic	Hemispheric/Focal	Focal seizures which cannot be specified with ...
GNSZ	9 Generalized Non-Specific Seizure	Electrographic	Generalized	Generalized seizures which cannot be further c...
SPSZ	10 Simple Partial Seizure	Clinical & Electrographic	All	Partial seizures during consciousness; Type sp...
CPSZ	11 Complex Partial Seizure	Clinical & Electrographic	All	Partial Seizures during unconsciousness; Type ...
ABSZ	12 Absence Seizure	Clinical & Electrographic	Generalized	Absence Discharges observed on EEG; patient lo...
TNSZ	13 Tonic Seizure	Clinical & Electrographic	All	Stiffening of body during seizure (EEG effects...
CNSZ	14 Clonic Seizure	Clinical & Electrographic	All	Jerking/shivering of body during seizure
TCSZ	15 Tonic Clonic Seizure	Clinical & Electrographic	All	At first stiffening and then jerking of body (...)
ATSZ	16 Atonic Seizure	Clinical & Electrographic	NaN	Sudden loss of muscle tone
MYSZ	17 Myoclonic Seizure	Clinical & Electrographic	NaN	Myoclonous jerks of limbs
NESZ	18 Non-Epileptic Seizure	Clinical & Electrographic	NaN	Any non-epileptic seizure observed. Contains n...
INTR	19 Interesting Patterns	Electrographic	All	Any unusual or interesting patterns observed t...
SLOW	20 Slowing	Electrographic	All	A brief decrease in frequency
EYEM	21 Eye Movement Artifact	Clinical & Electrographic	Focal	A very common frontal/prefrontal artifact seen...
CHEW	22 Chewing Artifact	Clinical & Electrographic	All	A specific artifact involving multiple channel...
SHIV	23 Shivering Artifact	Clinical & Electrographic	All	A specific, sustained sharp artifact that corr...
MUSC	24 Muscle Artifact	Clinical & Electrographic	All	A very common, high frequency, sharp artifact ...
ELPP	25 Electrode Pop Artifact	Clinical & Electrographic	Focal	A short artifact characterized by channels usi...
ELST	26 Electrostatic Artifact	Clinical & Electrographic	All	Artifact caused by movement or interference on...

شکل ۱۳.۳: داده‌های خام این دادگان

²NEDC TUH EEG Seizure corpus



شکل ۱۴.۳: ترسیم داده‌ها



شکل ۱۵.۳: جایگاه سنسورها [۲۲]

فصل ۴

آزمایش‌ها و نتیجه‌ها

۱۰۴ پیش‌پردازش و مهندسی ویژگی‌ها

مانند بیشتر سیگنال‌ها، داده‌های ثبت شده EEG دارای ابعاد متعددی از زمان، فرکانس، توان، فاز و فضا هستند. زمان به سادگی نحوه تغییر دامنه سیگنال ثبت شده در چندین نمونه متوالی است. فرکانس به سرعت (یا تعداد چرخه‌ها در ثانیه) نوسانات در سیگنال اشاره دارد و می‌تواند بر حسب هرتز یا π رادیان/نمونه (واحدهای نرمال شده که در آن یک نصف نرخ نمونه برداری است) نمایش داده شود. توان مقدار انرژی در یک باند فرکانسی است که با دامنه نوسان مجذور اندازه‌گیری می‌شود. فاز موقعیت یک نوسان در یک نقطه زمانی معین است که بر حسب رادیان یا درجه اندازه‌گیری می‌شود. توان و فاز دو عنصر یک بعدی هستند که به ترتیب اطلاعات مستقلی در مورد قدرت فعالیت خاص باند فرکانس و زمان‌بندی فعالیت ارائه می‌کنند. فضا به محل الکترودها روی پوست سر اشاره دارد. یک مونتاژ رایج سیستم ۱۰-۲۰ الکترود است که الکترودها را در فواصل استاندارد از هم قرار می‌دهد تا پوست سر را بپوشاند [۱۱].

فعالیت ریتمیک مغز حاوی فرکانس‌های متعددی است که همپوشانی دارند که می‌توانند از طریق تکنیک‌های پردازش سیگنال از هم جدا شوند. اینها معمولاً به باندهای دلتا (۲-۴ هرتز)، تتا (۴-۸ هرتز)، آلفا (۸-۱۲ هرتز)، بتا (۱۵-۳۰ هرتز)، گامای پایین (۳۰-۸۰ هرتز)، و گامای بالایی (۸۰-۱۵۰ هرتز) گروه‌بندی می‌شوند. باندهای دیگر عبارتند از ساب دلتا و امگا (تا ۶۰۰ هرتز)، اما این باندها به دلیل محدودیت‌های مربوط به توانایی EEG فعلی پوست سر برای نمایش چنین سیگنال‌هایی، کمتر در ادبیات ارائه شده‌اند. گروه‌بندی نوسانات مغز به‌طور آزاد مکانیسم‌های عصبی زیست‌شناختی نوسانات مغزی، مانند پوسیدگی سیناپسی و دینامیک انتقال سیگنال را منعکس می‌کند. با فرکانس‌های سریع‌تر، مانند گاما، تصور می‌شود که به‌طور کلی پردازش محلی را منعکس می‌کند و فرکانس‌های کندتر، مانند دلتا، که شبکه‌های مقیاس بزرگ‌تر را منعکس می‌کند. هر فعالیت نوسانی نیز با عملکردهای شناختی جداگانه همراه است. به عنوان مثال، ریتم آلفا با فعال سازی قشر همبستگی منفی دارد، که نشان می‌دهد می‌تواند بازدارندگی را منعکس کند [۲۲].

آماده‌سازی سیگنال داده‌های EEG ابتدا برای استخراج ویژگی با نمونه برداری مناسب و ارجاع سیگنال خام آماده می‌شوند. نمونه برداری EEG باید از معیار نایکوئست^۱ پیروی کند، بنابراین باید نرخ نمونه برداری مناسب در طول جمع‌آوری داده‌ها انتخاب شود تا اطمینان حاصل شود که مستعارسازی^۲ بر سیگنال مورد علاقه تأثیر نمی‌گذارد. سپس می‌توان برای تأکید بر تفاوت در فعالیت الکتریکی بین الکترودها، ارجاع مجدد انجام داد. شناخته‌شده‌ترین روش مرجع مجدد برای تشخیص تشنج بصری از گوش‌های مرتبط یا ماستوئید استفاده می‌کند که می‌تواند برای نشان دادن الگوی سنبله و موج در تشنج‌ها در دامنه وسیعی مورد استفاده قرار گیرد، اما می‌تواند برخی سوگیری را ایجاد کند. سایر روش‌های رایج مرجع مجدد، میانگین تمام الکترودها را با EEG با چگالی بالا حذف می‌کنند و الکترودها را برای ارجاع به الکترودهای همسایه (ارجاع دوقطبی) پیکربندی می‌کنند [۲]. به عنوان بخشی از پیش پردازش، یا در حین استخراج ویژگی، داده‌ها را می‌توان فیلتر کرد تا فرکانس‌هایی در فرکانس نایکوئست یا بالاتر از آن حذف شود، که تحت تأثیر مستعارسازی قرار می‌گیرد. نویز را می‌توان با کاهش فرکانس‌های مورد نظر نیز مهار کرد. سرکوب فرکانس‌های بالا اثرات برخی از حالات غیرعادی^۳ و نویز خط را از بین می‌برد و سرکوب فرکانس‌های زیر ۱۰ هرتز اثرات جابجایی ولتاژ آهسته ناشی از پتانسیل‌های پوست را کاهش می‌دهد. با این حال، اگر سیگنال و نویز در فرکانس‌های مشابه نوسان داشته باشند، کاهش نویز می‌تواند بدون تحریف سیگنال مورد نظر مشکل باشد. همچنین می‌توان از استراتژی‌هایی برای مقابله با حالات غیرعادی استفاده کرد، مانند حذف دوره‌ها یا کانال‌های دارای غیرعادی بیش از حد، حذف با استفاده از روش‌های جداسازی، یا آموزش سیستمی برای شناسایی و مقابله با غیرعادی رایج [۲۲]. روش‌های پیش‌پردازش عمومی‌تر شامل برخورد با مقادیر گمشده، با استراتژی‌هایی از جمله حذف، میانگین/میانة انتساب، یا استفاده از روش‌های بیشترین مقدار، و رمزگذاری^۴ ویژگی‌های اسمی با استفاده از روش‌هایی مانند رمزگذاری یک‌طرفه است [۱۰].

فیلترکردن:

کلاس‌های فیلتر رایج عبارتند از:

- **Low-pass**: فرکانس‌های پایین را عبور داده و فرکانس‌های بالا را کاهش می‌دهد.
- **High-pass**: فرکانس‌های بالا را عبور داده و فرکانس‌های پایین را کاهش می‌دهد.
- **Band-pass**: عبور یک محدوده فرکانس متوسط،
- **Notch**: فقط یک باند باریک از فرکانس‌ها را کاهش می‌دهد.

در ساخت فیلترها باید چندین ویژگی مشخص شود:

¹Nyquist

²aliasing

³artefacts

⁴encoding

- **فرکانس جداسازی**^۵: فرکانسی که باند عبور و باند توقف را از هم جدا می کند. در یک محیط بهینه این فرکانس است که سیگنال را از نویز جدا می کند.
- **رول آف**^۶: شیب پاسخ بزرگی در باند انتقال بین باند عبور و توقف. نوارهای انتقال باریک منجر به رول کردن فیلتر شیب دار و نوارهای انتقال گسترده به رول آف کم عمق می شود.

اکثر فیلترها تضعیف کاملی در باند توقف ندارند، با این انحراف معمولاً تضعیف باند توقف^۷ نامیده می شود و هنگامی که در باند عبور است موج دار می شود. اکثر فیلترها همچنین باعث تأخیر فاز می شوند، فیلترهایی که به عنوان فاز خطی توصیف می شوند، دارای این تأخیر برابر در سراسر باندهای فرکانسی هستند که می توان با جابجایی خروجی فیلتر و در نتیجه فیلتر فاز صفر آن را اصلاح کرد. تأخیر فاز صفر را می توان در فیلترهای غیر خطی با فیلتر کردن مجدد خروجی فیلتر در جهت معکوس (فیلتر دو پاس، فیلتر فیلتر) به دست آورد. با این حال، این فیلتر مضاعف ترتیب فیلتر و طول پاسخ ضربه ای (موثر) را دو برابر می کند. فیلترهای دیجیتال را می توان به عنوان فیلترهای پاسخ ضربه محدود^۸ یا پاسخ ضربه نامحدود^۹ پیاده سازی کرد.

فیلتر FIR: یک فیلتر پایین گذر FIR ایده آل با فرکانس ۴۰ هرتز پاسخی به بزرگی ۱ را در باند عبور تا ۴۰ هرتز می دهد، که در آن به یک پاسخ به بزرگی ۰ تا فرکانس نایکوئیست تغییر می کند.

فیلتر IIR: یک فیلتر IIR می تواند سیگنال را به طور مداوم خروجی دهد. همانند فیلترهای FIR، مجموع وزنی نمونه های ورودی را محاسبه می کند، اما مجموع وزنی نمونه های خروجی قبلی را نیز اضافه می کند. برای فیلترهای IIR، هم تضعیف و هم تأخیر به فرکانس قطع بستگی دارد، با این حال این نیز منجر به تفاوت در تأخیر فاز می شود. با سیگنال های فرکانس پایین معمولاً بیشتر از سیگنال های فرکانس بالا تأخیر می افتد. دو فیلتر روشاوت IIR عبارتند از باتروث^{۱۰} و بیضوی^{۱۱} [۱۶].

مهندسی ویژگی ها: کلید عملکرد هر الگوریتم یادگیری ماشین استخراج موفقیت آمیز ویژگی های برجسته است که می تواند هم از دانش حوزه و هم از تکنیک های استخراج ویژگی محاسباتی حاصل شود. بنابراین شروع هر پروژه یادگیری ماشینی شناسایی ویژگی های مرتبط از دانش داده ها، در این مورد سری های زمانی، یا ادبیات قبلی در آن حوزه است. برای این پایان نامه به تعدادی از ویژگی های خاص برای صرع که روی آنها کار شده و به چند مورد از ویژگی ها، پرداخته شده است. روش های استفاده شده عبارتند از: تبدیل فوریه، روش ولش، تبدیل موجک، آنتروپی و استفاده از همبستگی و مقادیر ویژه [۲۲]. پس از انجام آماده سازی ها و روش های گفته شده، نتایج هر مدل یادگیری ماشین و یادگیری عمیق را بررسی

⁵Cutoff Frequency

⁶Roll-off

⁷stopband attenuation

⁸FIR

⁹IIR

¹⁰Butterworth

¹¹Elliptic

می‌کنیم. برای یادگیری نظارت‌شده، از معیار درستی استفاده شده است (در قسمت ارزیابی مدل معیارهای دقیق‌تر و مناسب‌تر برای مسئله ما معرفی و بررسی شده و از آن به بعد در نتایج از آنها بهره گرفته شده است). برای هر دسته از مدل‌ها (نظارت‌شده، گروهی، پرسپترون چندلایه‌ای و شبکه عصبی پیچشی) از دیتاست‌های معرفی‌شده در فصل مربوطه، با توجه به شرایط، محدودیت‌ها و توانایی مدل، به ترتیب استفاده شده است.

۲.۴ ارزیابی مدل و تنظیم فرایارامتر

معیارهای ارزیابی مدل: در اینجا قصد داریم روش‌هایی برای ارزیابی عملکرد طبقه‌بندی‌کننده‌ها و نحوه تنظیم فرایارامترهای مدل‌ها برای تطبیق بهتر داده‌هایمان را بررسی کنیم. این کار ما را قادر می‌سازد تا درک بهتری از نحوه تعمیم مدل‌ها به داده‌های غیرقابل مشاهده داشته باشیم و همچنین عملکرد بهتری را از مدل‌های خود دریافت کنیم. ابتدا نگاهی به یک «ماتریس سردرگمی» بیندازیم که مدل ماشین بردار پشتیبان با داده‌های اعتبارسنجی مطابقت دارد. یک ماتریس سردرگمی نشان می‌دهد که برچسب پیش‌بینی‌شده مدل‌ها چه بوده و برچسب واقعی چیست. با استفاده از این ماتریس سردرگمی، می‌توانیم به صورت دستی چندین معیار عملکرد مختلف را بررسی کنیم.

		Predicted Label	
		Baseline	Seizure
True Label	Baseline	33	2
	Seizure	0	13

شکل ۱.۴: ماتریس سردرگمی برای استخراج معیارهای دقت

معیارهای بدست آمده:

Error and accuracy:

$$Accuracy = \frac{TP + TN}{TP + FP + TN + FN} \quad (۱.۴)$$

خطا و دقت اطلاعات عملکرد کلی را در مورد تعداد تمام پیش‌بینی‌های درست یا نادرست در مقایسه با تعداد کل پیش‌بینی‌ها برای برچسب‌های مثبت و منفی ارائه دهید.

Recall or True Positive Rate:

$$Recall = \frac{TP}{TP + FN} \quad (۲.۴)$$

فراخوانی (یا نرخ مثبت واقعی) محاسبه می‌کند که مدل ما چه تعداد از نکات مثبت واقعی را به درستی یا نادرست برچسب گذاری کرده است. این زمانی مفید است که کسری از نمونه های به درستی یا اشتباه طبقه بندی شده در کلاس مثبت مورد توجه باشد.

Precision (PRE):

$$Precision = \frac{TP}{TP + FP} \quad (3.4)$$

دقت، با نگاه کردن به اینکه چند برچسب مثبت پیش بینی شده واقعاً مثبت هستند، اطلاعاتی درباره دقت بودن مدل شما می‌دهد. برای محاسبه آن، فقط مثبت های واقعی را بگیرید و آن را بر مجموع مثبت های درست و نادرست تقسیم کنید. دقت معیار خوبی برای تعیین زمانی است که هزینه های یک مثبت کاذب زیاد است.

F1-score

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall} \quad (4.4)$$

امتیاز F1 ترکیبی از Precision و Recall است که زمانی استفاده می‌شود که به دلیل تعداد زیادی از منفی های واقعی که روی آن‌ها تمرکز ندارید، توزیع کلاسی نامتوازن وجود دارد [17]. ممکن است برخی معیارهای مختلف بسته به حوزه استفاده مناسب تر باشند. به عنوان مثال، اولویت ممکن است به جای تشخیص صحیح دوره های اینتراکتال، شناسایی تشنج ها باشد، بنابراین فراخوانی روش بهتری برای بررسی خواهد بود. اگر ما بیمارانی که در معرض خطر مرگ غیرمنتظره ناگهانی در صرع (SUDEP) هستند را در نظر بگیریم، هزینه های داشتن یک مثبت واقعی (یا منفی کاذب) طبقه بندی نشده بسیار زیاد است.

معیارهایی دیگر:

منحنی مشخصه عملیاتی گیرنده (ROC): منحنی های ROC برای مقایسه مدل های طبقه بندی بر اساس عملکرد نرخ مثبت کاذب و مثبت واقعی مفید هستند. یک منحنی ROC با جابجایی آستانه تصمیم طبقه بندی کننده محاسبه می‌شود.

منحنی فراخوانی-دقت: منحنی فراخوان دقت، مبادله بین دقت و فراخوان را برای آستانه های مختلف نشان می‌دهد. یک ناحیه بالا در زیر منحنی هم فراخوانی بالا و هم دقت بالا را نشان می‌دهد، که در آن دقت بالا به نرخ مثبت کاذب پایین مربوط می‌شود و فراخوانی بالا مربوط به مقدار نادرست کم است. نرخ منفی نمرات بالا برای هر دو نشان می‌دهد که طبقه بندی کننده نتایج دقیق (دقت بالا) و همچنین اکثر نتایج مثبت (فراخوانی بالا) را برمی گرداند. یک سیستم با فراخوانی بالا اما دقت کم نتایج بسیاری را برمی گرداند، اما بیشتر برچسب های پیش بینی شده آن در مقایسه با برچسب های آموزشی نادرست هستند. سیستمی با دقت بالا اما فراخوانی کم درست برعکس است و نتایج بسیار کمی را برمی گرداند، اما بیشتر برچسب های پیش بینی شده آن در مقایسه با برچسب های آموزشی درست هستند. یک سیستم ایده آل با دقت بالا و فراخوانی بالا، نتایج بسیاری را به همراه خواهد داشت و همه نتایج به درستی برچسب گذاری

شده‌اند[۹]. منحنی‌های این روابط در دادگان‌های غیرمتوازن مفید هستند، مانند زمانی که کلاس مثبت نادر است، یا زمانی که موارد مثبت کاذب مهم‌تر از منفی‌های کاذب هستند. در غیر این صورت منحنی ROC به طور کلی مفیدتر است.

منحنی یادگیری: منحنی‌های یادگیری را می‌توان برای مشاهده اینکه آیا الگوریتم مشکلی با برازش بیش از حد (واریانس بالا) یا عدم تناسب (بایاس زیاد) به داده‌های آموزشی دارد استفاده کرد. ممکن است این مدل برای دادگان آموزشی بسیار پیچیده باشد و باعث شود آن را به خوبی به داده‌های دیده نشده تعمیم ندهد. با اضافه کردن داده‌های آموزشی بیشتر، می‌توانیم درجه‌ای که یک مدل بیش از حد/کم‌تر برازش داده‌های آموزشی است را ترسیم کنیم. آنچه ما به دنبال آن هستیم این است که با افزایش تعداد نمونه‌های آموزشی، معیارهای امتیازدهی انتخابی برای آموزش و مجموعه‌های تست به هم نزدیک‌تر شوند. آنچه که این منحنی‌ها در مورد مدل ما به ما می‌گویند این است که احتمالاً بیش از حد با داده‌های آموزشی مطابقت دارند. برای پرداختن به این موضوع می‌توانیم:[۱۷]

- جمع‌آوری داده‌های آموزشی بیشتر
- کاهش پیچیدگی مدل
- افزایش پارامتر تنظیم
- تعداد ویژگی‌ها را از طریق انتخاب ویژگی یا استخراج ویژگی کاهش دهید.

اعتبارسنجی متقاطع^{۱۲}: تاکنون ما فقط عملکرد مدل‌های خود را در تقسیم داده‌های خود به آموزش، اعتبارسنجی و مجموعه‌های آزمایشی (روش نگه‌داری^{۱۳}) ارزیابی کرده‌ایم. مجموعه اعتبارسنجی در طول آموزش و تنظیم فرایارامترها استفاده می‌شود، و مجموعه آزمون را می‌توان پس از انتخاب مدل نهایی برای ارزیابی عملکرد نهایی استفاده کرد. این یک رویکرد محبوب برای عملکرد تعمیم است، [۱۷] با این حال، ما نمی‌توانیم از مجموعه اعتبارسنجی یکسانی در هنگام آزمایش ابرپارامترهای مختلف استفاده کنیم، زیرا مدل به احتمال زیاد بیش از حد به داده‌های فعلی تناسب دارد و در هنگام استقرار کمتر قابل تعمیم است.


اعتبارسنجی متقاطع کا-چین‌خورده^{۱۴}: روش Holdout یک نقطه ضعف دارد، زیرا در جایی که تقسیم‌بندی مجموعه‌های آموزشی، اعتبارسنجی و تست هستند بر عملکرد تأثیر می‌گذارند. بنابراین، یک تکنیک قوی‌تر، تقسیم داده‌های آموزشی به مجموعه‌های آموزشی و اعتبارسنجی چندگانه است. ما به طور تصادفی مجموعه آموزشی را بدون جایگزینی به k تاها تقسیم می‌کنیم، بنابراین از $k-1$ تا برای آموزش مدل استفاده می‌شود و یکی برای ارزیابی عملکرد استفاده می‌شود. با تکرار k بار، k مدل و برآورد

¹²Cross-Validation

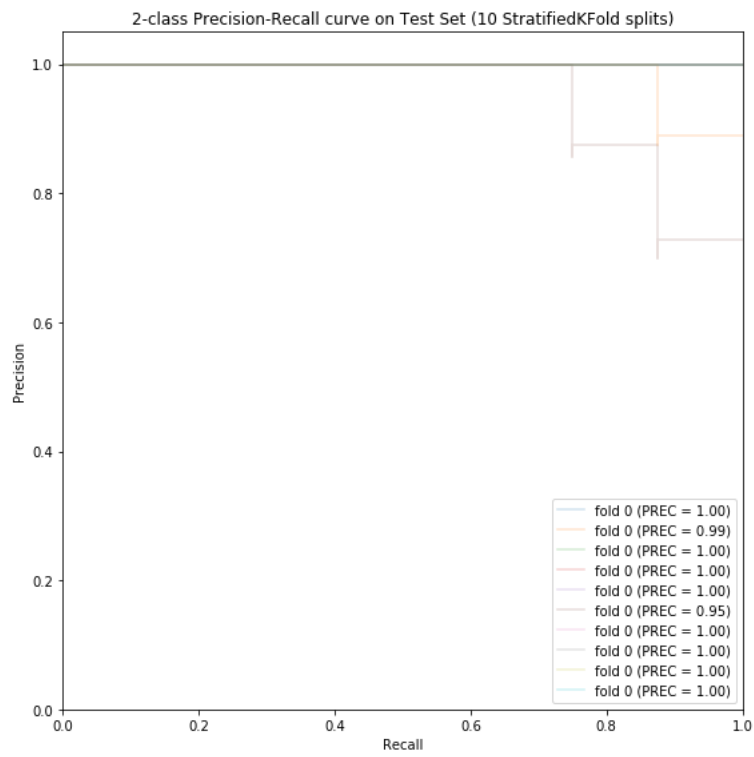
¹³holdout

¹⁴K-Fold Cross-Validation

عملکرد به دست می‌آید که میانگین عملکرد از آن‌ها گرفته می‌شود. از آنجایی که اعتبارسنجی متقاطع کا-چین خورده نمونه‌گیری مجدد بدون جایگزینی انجام می‌شود، هر نقطه نمونه در هر دو مجموعه آموزشی و اعتبارسنجی یک بار استفاده می‌شود [۱۷]. یک مقدار پیش‌فرض خوب برای K مقدار ۱۰ است، اما اگر مجموعه‌های آموزشی کوچک هستند، ممکن است بهتر باشد تعداد را افزایش دهید و اگر داده‌ها بزرگ هستند، آن را کاهش دهید [۱۷]. از منحنی‌های ROC و منحنی دقت نیز می‌توان برای مشاهده تفاوت عملکرد در هر چین یا فولد استفاده کرد.



شکل ۲.۴: منحنی ROC اعتبارسنجی متقاطع



شکل ۳.۴: منحنی دقت اعتبارسنجی متقاطع

تنظیم فرایارامتر: هر مدل یادگیری ماشینی دارای مجموعه‌ای از پارامترها است که می‌تواند روی مقادیر مختلف تنظیم شود. در حال حاضر ما عمدتاً از پارامترهای پیش‌فرض برای طبقه‌بندی‌کننده‌مان استفاده می‌کنیم، یا آنها را به صورت دستی تنظیم می‌کنیم، اما مدل ما احتمالاً می‌تواند بهبود یابد اگر این پارامترها را برای تناسب بهتر با داده‌ها تغییر دهیم. حساسیت به تنظیمات هایپرپارامتر بسته به طبقه‌بندی‌کننده تغییر می‌کند. به عنوان مثال رگرسیون لجستیک نسبتاً به تنظیمات فرایارامتر حساس نیست. با این حال، یافتن محدوده مناسب فرایارامتر هنوز ضروری است، در غیر این صورت تفاوت بین مدل‌ها ممکن است فقط به پارامترهای تنظیم پیش‌فرض مربوط شود تا رفتار مدل یا ویژگی‌ها [۲۴]. روش‌هایی برای انجام این کار عبارتند از: جستجوی شبکه‌ای، جستجوی تصادفی، بهینه‌سازی بیزی و منحنی‌های اعتبارسنجی.


جستجوی شبکه‌ای^{۱۵}: جستجوی شبکه‌ای یک الگوی جستجوی جامع است که در آن فهرستی را در داخل یک فرهنگ لغت با مقادیر مختلف برای فرایارامترهای مختلف مشخص می‌کنیم. کامپیوتر از این لیست برای ارزیابی عملکرد مدل برای هر ترکیبی از مقادیر استفاده می‌کند تا مجموعه‌ای را به دست آورد که بهترین امتیازدهندگان را در معیار عملکرد داده شده بدست آورد. برای ماشین‌های بردار پشتیبان، مقادیری که ما تغییر می‌کنیم سی و گاما هستند. سی جریمه طبقه‌بندی اشتباه را کنترل می‌کند، با مقادیر بزرگ‌تر مربوط به جریمه‌های خطای بزرگ‌تر، به این معنی که می‌توانیم از آن برای کنترل پهنای حاشیه در اطراف مرز تصمیم‌گیری و در نتیجه تنظیم مبادله بایاس واریانس استفاده کنیم. گاما اساساً یک پارامتر برش برای پارامتر هسته است، با افزایش مقادیر، تأثیر نمونه‌های آموزشی را افزایش می‌دهد تا یک مرز تصمیم‌گیری غیرخطی محکم‌تر ایجاد کند [۱۷].

جستجوی تصادفی: جستجوی شبکه‌ای یک روش قدرتمند است، اما از نظر محاسباتی گران است زیرا باید تمام ترکیبات پارامترهای ممکن را ارزیابی کند. اگر با یک دادگان بزرگ‌تر کار می‌کردیم، بسیار بهتر است که به صورت تصادفی از ترکیبات مختلف پارامترهای تصادفی در یک محدوده مشخص نمونه برداری کنیم [۲۲].

بهینه‌سازی بیزی: بهینه‌سازی فرایارامترهای یک مدل یادگیری ماشینی را می‌توان به عنوان یک مشکل کمینه‌سازی در نظر گرفت، زیرا ما به دنبال کمترین ضرر اعتبارسنجی هستیم. بهینه‌سازی بیزی یک مدل احتمالی است که می‌تواند کارآمدتر از جستجوی دستی، تصادفی یا شبکه‌ای برای یافتن فرایارامترهای بهینه باشد [۱۷].

منحنی‌های اعتبارسنجی: همچنین می‌توانیم با استفاده از منحنی‌های اعتبارسنجی، ابرپارامترها را به صورت دستی تنظیم کنیم. منحنی‌های اعتبارسنجی بسیار شبیه به منحنی‌های یادگیری هستند، اما در عوض دقت‌های آموزش و آزمون را ترسیم می‌کنند تا ببینند یک برآوردگر هنگام تغییر پارامترهای مدل چگونه عمل می‌کند.

¹⁵Grid Search



شکل ۴.۰: یک منحنی اعتبارسنجی برای مثال

۳.۴ کاهش ابعاد

به منظور کاهش پیچیدگی مدل، زمان اجرا و پتانسیل تطبیق بیش از حد با داده های آموزشی، می توان از تکنیک های کاهش ابعاد استفاده کرد. به طور کلی می توان آنها را به روش هایی دسته بندی کرد که زیرمجموعه ای از مجموعه اصلی ویژگی ها (انتخاب ویژگی) ایجاد می کنند و روش هایی که ویژگی های مصنوعی جدید را از طریق ترکیب ویژگی های اصلی و کنار گذاشتن ویژگی های کمتر مهم ایجاد می کنند (استخراج ویژگی). اساساً ما می خواهیم «اطلاعات غیر اطلاعاتی» را حذف کنیم و بیت های مفید را حفظ کنیم. اگر ویژگی های زیادی دارید، ممکن است برخی از آنها بسیار همبسته و در نتیجه زائد باشند. بنابراین ما می توانیم فقط برخی از آنها را انتخاب کنیم، یا آنها را در یک زیرفضای با ابعاد پایین تر فشرده کنیم [۲۴].

انتخاب ویژگی ها: با تنظیم $TEST\ SIZE = 0.2$ شروع می کنیم. ویژگی هایی را که برای طبقه بندی مفید نیستند حذف می کند تا پیچیدگی مدل را کاهش دهد. زمان آموزش برای اکثر مدل های یادگیری ماشین به صورت خطی با تعداد ویژگی ها مقیاس می شود، با برخی از ویژگی ها حتی بدتر، بنابراین یافتن مدلی ساده که دقت پیش بینی را از دست نمی دهد، اما محاسبه آن سریع تر است مفید است. برای این کار روش هایی مانند فیلترکردن، روش های تعبیه شده، روش های لفاف دار، چیدمان مدل و ارزیابی اهمیت ویژگی ها با جنگل های تصادفی وجود دارند [۲۴].


استخراج ویژگی ها: مشابه انتخاب ویژگی، روش های مختلف استخراج ویژگی می تواند برای کاهش تعداد ویژگی ها برای طبقه بندی استفاده شود. استخراج ویژگی با انتخاب ویژگی متفاوت است زیرا داده ها به جای حفظ ویژگی های اصلی به یک فضای ویژگی جدید تبدیل می شوند. علاوه بر سرعت بخشیدن به آموزش، کاهش ابعاد برای تجسم داده ها مفید است زیرا می تواند یک مجموعه آموزشی با ابعاد بالا را به یک مجموعه دو یا سه بعدی کاهش دهد. جداسازی منبع کور (BSS) به طور گسترده شامل رویکردهایی می شود که هدف آنها جداسازی مجموعه ای از سیگنال های مختلط به منابع جزء خود با

اطلاعات کمی در مورد فرآیند اختلاط است. تکنیک‌های کاهش خطا عبارتند از جاسازی خطی محلی، مقیاس‌بندی چندبعدی، تی-توکاری همسایگی تصادفی توزیع شده^{۱۶}، ایزومپ و غیره. وجود دارد [۹]. روش‌هایی مانند استفاده از تجزیه و تحلیل مولفه اصلی و روش هسته‌ای آن و یومپ هستند.

۴.۴ یادگیری تحت نظارت

داده‌ها به مجموعه‌های آموزشی و آزمایشی تقسیم می‌شوند که نسبت‌های کلاسی مشابه داده‌های اصلی دارند. ($TEST\ SIZE = 0.1$) این به این دلیل است که بعداً وقتی مدل طبقه‌بندی را برای پیش‌بینی یک کلاس در داده‌ها تنظیم می‌کنیم، می‌خواهیم پیش‌بینی‌ها را با برخی از برجسته‌های واقعی در یک گروه جداگانه از داده‌ها (مجموعه آزمایش) مقایسه کنیم تا قبل از استفاده، یک ارزیابی عملکرد بی‌طرفانه از مدل خود ارائه دهیم. متعادل کردن از دست دادن اطلاعات در مجموعه آموزشی و تخمین خطای تعمیم مدل‌ها مستلزم در نظر گرفتن اندازه داده‌ها است. از آنجایی که ما داده‌هایی را که الگوریتم می‌تواند از آن‌ها بیاموزد را برای مجموعه آزمایشی که نمی‌خواهیم اطلاعات زیادی را مخفی کنیم، مخفی می‌کنیم، هر چه مجموعه آزمون کوچک‌تر باشد، تخمین خطای تعمیم نادقیق‌تر است.

رگرسیون لجستیک: رگرسیون لجستیک یک مدل خطی برای طبقه‌بندی یک متغیر وابسته است که دارای تعداد محدودی مقادیر ممکن است. رگرسیون لجستیک یک مدل احتمالی است که از نسبت شانس برای تعیین احتمال طبقه‌بندی یک رویداد استفاده می‌کند. در طبقه‌بندی باینری، اگر احتمال تخمین زده شده بیشتر از ۵۰٪ باشد، نمونه پیش‌بینی می‌شود که کلاس مثبت (مثلاً اکتال) باشد، در غیر این صورت کلاس منفی (مثلاً بین اکتال) پیش‌بینی می‌شود [۹].



شکل ۵.۴: طبقه‌بندی به وسیله رگرسیون لجستیک

ماشین‌های بردار پشتیبان (SVM): یکی دیگر از الگوریتم‌های متمایز روش‌هاول است که برای دادگان‌های پیچیده کوچک تا متوسط مناسب است. زیرمجموعه‌ای از داده‌های آموزشی، که به عنوان

¹⁶:t-Distributed Stochastic Neighbor Embeddin (t-SNE)

بردارهای پشتیبانی شناخته می‌شوند، توسط یک الگوریتم برای محاسبه ابر صفحه جداسازی بهینه بین کلاس‌ها انتخاب می‌شوند. اگر بتوان داده‌ها را به صورت خطی جدا کرد، می‌توان از «حاشیه سخت» جداسازی استفاده کرد. به موجب آن یک نقطه در لبه یک کلاس به عنوان بردار پشتیبان برای مرز تصمیم استفاده می‌شود. این روش به موارد دورافتاده حساس است، بنابراین یک روش انعطاف‌پذیرتر ممکن است ترجیح داده شود، با استفاده از یک حاشیه نرم از جداسازی برای محاسبه یک ابر صفحه که همچنان حداکثر حاشیه جدایی را فراهم می‌کند، در حالی که هنوز برای برخی از خطاها مجاز است [۹] [۲۲]. برای SVM ما فقط از SVC استفاده می‌کنیم و هسته^{۱۷} را روی خطی^{۱۸} قرار می‌دهیم تا بتوانیم مرز تصمیم را با رگرسیون لجستیک مقایسه کنیم. اگر کرنل را روی تابع برمبنای شعاع^{۱۹} بگذاریم، نتایج بهتری می‌گیریم.

درخت تصمیم‌گیری: یک درخت تصمیم با پرسیدن یک سری سوال به منظور دسته‌بندی نمونه‌ها در یک کلاس، داده‌ها را تجزیه می‌کند. یک الگوریتم از ریشه درخت شروع می‌شود و سپس داده‌ها را بر اساس ویژگی‌هایی تقسیم می‌کند که بیشترین سود اطلاعات را به همراه دارد. این روش تقسیم تا زمانی اتفاق می‌افتد که تمام نمونه‌های درون یک گره معین، همه به یک کلاس تعلق داشته باشند. محدودیتی در گره‌ها یا عمق درخت اغلب برای جلوگیری از برازش بیش از حد به دلیل وجود درخت عمیق تعیین می‌شود. برای تقسیم با استفاده از به دست آوردن اطلاعات، متکی به محاسبه تفاوت بین اندازه‌گیری ناخالصی یک گره والد و مجموع ناخالصی‌های گره‌های فرزند آن است. هنگامی که ناخالصی گره‌های فرزند کم باشد، به دست آوردن اطلاعات زیاد است. سه معیار ناخالصی که معمولاً در درخت‌های تصمیم‌بایزری استفاده می‌شوند عبارتند از: ناخالصی جینی، آنتروپی و خطای طبقه‌بندی. مجموعه‌ای از درخت‌های تصمیم را می‌توان برای ساخت یک مدل قوی‌تر با دادن یک نمونه بوت استرپ تصادفی از داده‌ها به هر درخت و استفاده از قانون رأی اکثریت برای پیش‌بینی لیبیل یک کلاس ایجاد کرد [۱۷].

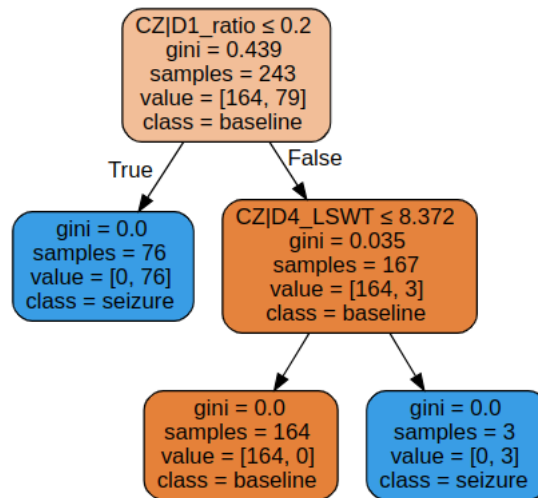
کا-نزدیکترین همسایه‌ها^{۲۰}: KNN تعدادی از نمونه‌ها را پیدا می‌کند که شبیه‌ترین نمونه‌ها به نقطه داده‌ای هستند که می‌خواهیم بر اساس یک متریک فاصله معین، با برجسب کلاس اختصاص داده شده آن بسته به رای اکثریت توسط نزدیک‌ترین همسایگان، طبقه‌بندی کنیم. KNN به عنوان یک یادگیرنده تنبل طبقه‌بندی می‌شود، زیرا داده‌های آموزشی را به جای یادگیری یک تابع متمایز به خاطر می‌سپارد. تعداد k و یک متریک فاصله باید مشخص شود (اغلب فاصله اقلیدسی با داده‌های با ارزش واقعی؛ پیش‌فرض در اسکیلرن)، با الگوریتمی که از اینها برای طبقه‌بندی یک نمونه استفاده می‌کند و با اکثریت آرا با استفاده از K نمونه‌ها در مجموعه آموزشی که بیشترین شباهت را به نقطه‌ای که می‌خواهیم نمونه برداری کنیم، به آن برجسب اختصاص می‌دهد. با در دسترس قرار گرفتن داده‌های جدید، طبقه‌بندی کننده را می‌توان به راحتی تطبیق داد، اما پیچیدگی طبقه‌بندی به صورت خطی با تعداد داده‌ها در

¹⁷kernel

¹⁸Linear

¹⁹Radial Basis Function

²⁰K-nearest neighbors



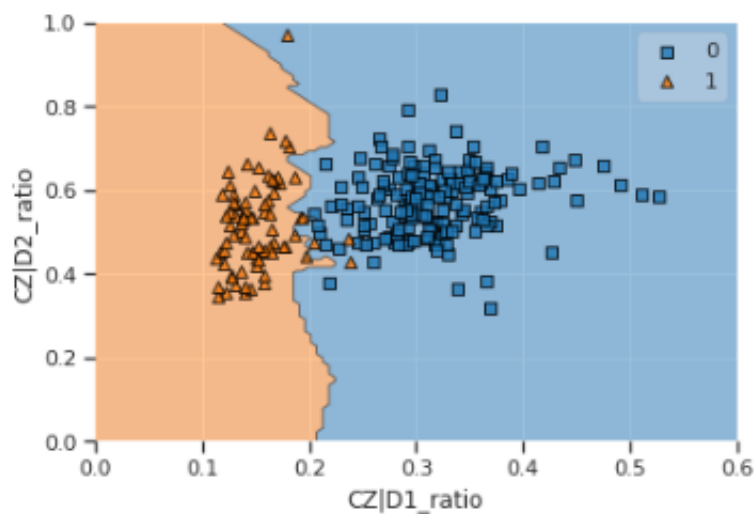
شکل ۶.۴: عملکرد درخت تصمیم‌گیری

مجموعه آموزشی افزایش می‌یابد. مگر اینکه از ساختارهای داده مانند درختان کاه-دی^{۲۱} استفاده شود. علاوه بر این، KNN به دلیل نفرین ابعادی مستعد بیش از حد برازش است، جایی که با افزایش تعداد ابعاد فضای ویژگی، فضای ویژگی کمتر می‌شود. اینجاست که تکنیک‌های کاهش ابعاد می‌توانند کمک کنند[۱۷].

می‌بینیم که SVM بهترین نتیجه را در این قسمت داشته است. نتایج روش‌های نظارت‌شده در جدول زیر آورده شده است:

Method	Accuracy Results
LR	0.963
SVM	1.000
DT	0.926
KNN	0.889

²¹KD-Trees



شکل ۷.۴: طبقه‌بندی به وسیله روش کاً-نزدیک‌ترین همسایه‌ها

Logistic Regression

		Predicted Label	
		Baseline	Seizure
True Label	Baseline	35	0
	Seizure	0	13

Support Vector Machine

		Predicted Label	
		Baseline	Seizure
True Label	Baseline	33	2
	Seizure	0	13

شکل ۸.۴: ماتریس سردرگمی برای رگرسیون لجستیک و SVM


Decision Tree

		Predicted Label	
		Baseline	Seizure
True Label	Baseline	34	1
	Seizure	0	13

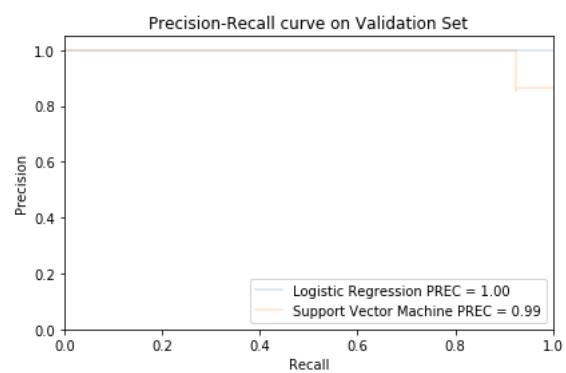
K-Nearest Neighbors

		Predicted Label	
		Baseline	Seizure
True Label	Baseline	35	0
	Seizure	3	10


شکل ۹.۴: ماتریس سردرگمی برای درخت تصمیم‌گیری و KNN



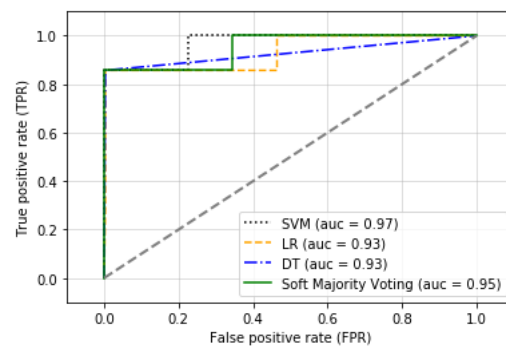
شکل ۱۰.۴: منحنی ROC برای روش‌های تحت نظارت



شکل ۱۱.۴: منحنی دقت-فراخوانی برای رگرسیون لجستیک و SVM



شکل ۱۲.۴: عملکرد SVM برحسب درستی و دقت

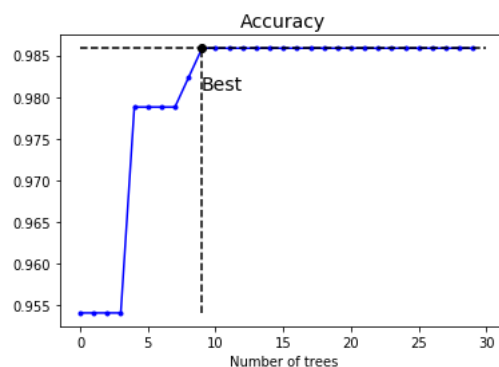


شکل ۱۳.۴: پیاده‌سازی soft majority voting بر ۳ روش اول نظارتی

۵.۴ یادگیری گروهی

تقویت گرادیان: این روش شبیه به شبیه به تقویت آدا عمل می‌کند، زیرا به‌طور متوالی پیش‌بینی‌کننده‌ها را برای تصحیح پیش‌دگرها در یک مجموعه اضافه می‌کند. با این حال به جای تغییر وزن، مدلی را با خطاهای باقیمانده مطابقت می‌دهد. برای این روش دو الگوریتم معروف داریم:

- **تقویت اکس جی^{۲۲}:** دو الگوریتم بسیار موثر، کارآمد و قابل موازی سازی که محبوب هستند تقویت اکس جی و لایت جی‌بی‌ام هستند. هر دو الگوریتم به روش‌های مختلفی الگوریتم‌های درخت تصمیم تقویت‌شده با گرادیان اصلی (GBDT) را بهبود می‌بخشند[۹].
- **لایت جی‌بی‌ام^{۲۳}:** روش‌های اضافه‌ای را نسبت به تقویت اکس جی برای یافتن بهترین تقسیم‌بندی ویژگی‌ها برای هر برگ ارائه می‌کند که شامل نمونه‌گیری فرعی داده و دسته‌بندی ویژگی‌های انحصاری می‌شود. نمونه‌برداری یک طرفه مبتنی بر گرادیان، که در لایت جی‌بی‌ام موجود است، به جای نقاط داده‌ای که کمتر به آموزش کمک می‌کنند، روی نقاط داده با گرادیان بزرگ‌تر تمرکز می‌کند. برای اطمینان از اینکه نادیده گرفتن شیب‌های کوچک منجر به نمونه‌گیری دارای سوگیری نمی‌شود، داده‌های با گرادیان‌های کوچک به‌طور تصادفی نمونه‌گیری می‌شوند و به این نمونه‌ها هنگام ارزیابی سهم آنها در تغییر از دست دادن وزن بیشتری داده می‌شود.



شکل ۱۴.۴: عملکرد تقویت گرادیان

تاثیر روش‌های تقویت گرادیان را در جدول زیر می‌بینیم:

^{۲۲}XgBoost

^{۲۳}LightGBM

Metric	0	1	Accuracy	Macro avg	Weighted avg
precision	1.000000	0.928571	0.996466	0.964286	0.996719
recall	0.996296	1.000000	0.996466	0.998148	0.996466
f1-score	0.998145	0.962963	0.996466	0.980554	0.996529
support	270.000000	13.000000	0.996466	283.000000	283.000000

۶.۴ پرسپترون چندلایه

ساخت مدل‌های یادگیری عمیق به معنای ایجاد خط لوله برای تبدیل داده‌ها است. هنگام استفاده از کراس، لایه‌هایی که به مدل‌های خود اضافه می‌کنیم به صورت پویا ساخته می‌شوند تا با شکل لایه ورودی مطابقت داشته باشند. معمولاً لایه‌ها به صورت خطی روی هم چیده می‌شوند تا یک ورودی را به یک خروجی نگاشت کنند، اما معماری‌های دیگری نیز وجود دارند (مانند شبکه‌های دو شاخه، شبکه‌های چند سر، بلوک‌های آغازین).

منظم‌سازی: قبلاً از روشهای این روش مواردی را دیده‌ایم، در اینجا روش‌های دیگری را هم معرفی می‌کنیم:

L1 و L2: همانند سایر مدل‌های خطی، می‌توانیم از این روش‌ها برای محدود کردن وزن اتصال شبکه استفاده کنیم. این را می‌توان با افزودن شرایط به تابع هزینه انجام داد.

ماکس-نورم^{۲۴}: برای هر نورون، وزن اتصالات ورودی محدود می‌شود و در صورت نیاز قطع می‌شود. مزایای این روش: کمک به کاهش بیش‌برازش کاهش گرادینان‌های در حال ناپدید شدن/انفجار (اگر از نرمال‌سازی دسته‌ای استفاده نمی‌شود)

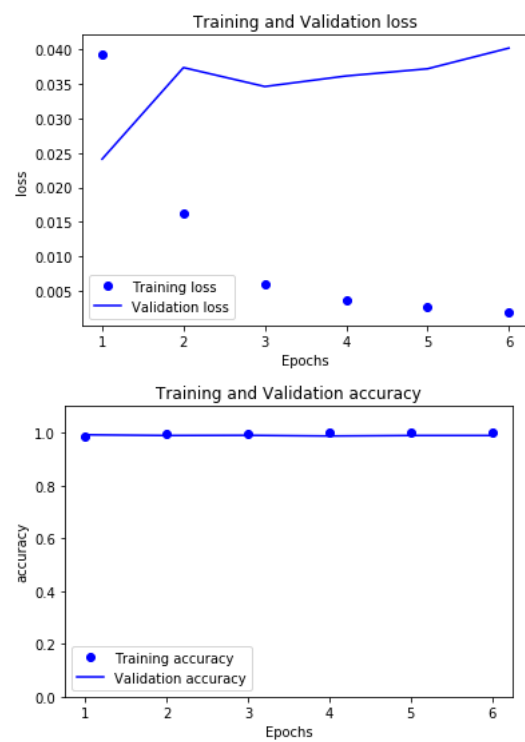
حذف^{۲۵}: این محبوب‌ترین روش منظم‌سازی است زیرا نشان داده شده است که دقت مدل‌های ابتدایی را بهبود می‌بخشد. در هر مرحله آموزشی، هر نورون ورودی احتمال دارد که موقتاً از بین برود. حذف معمولاً حدود ۵۰ درصد تعیین می‌شود. این حذف فقط در تمرین اتفاق می‌افتد. حذف به این معنی است که شبکه نمی‌تواند به چند نورون ورودی تکیه کند، به این معنی که قوی‌تر است و می‌تواند بهتر تعمیم یابد. نکته مهمی که باید به آن توجه کرد این است که اگر احتمال افت روی ۵۰ درصد تنظیم شود، به این معنی است که در طول آزمایش دو برابر ورودی‌ها وجود دارد. این بدان معناست که برای محاسبه این موضوع باید پس از آموزش وزن‌ها را در ۵۰ ضرب کنیم [۱۲].

طراحی مدل: تعداد فرایپارامترهای ممکن به این معنی است که یافتن بهترین راه برای راه اندازی شبکه عصبی دشوار است. گزینه‌ها شامل جستجوی دستی، جستجوی تصادفی و غیره است.

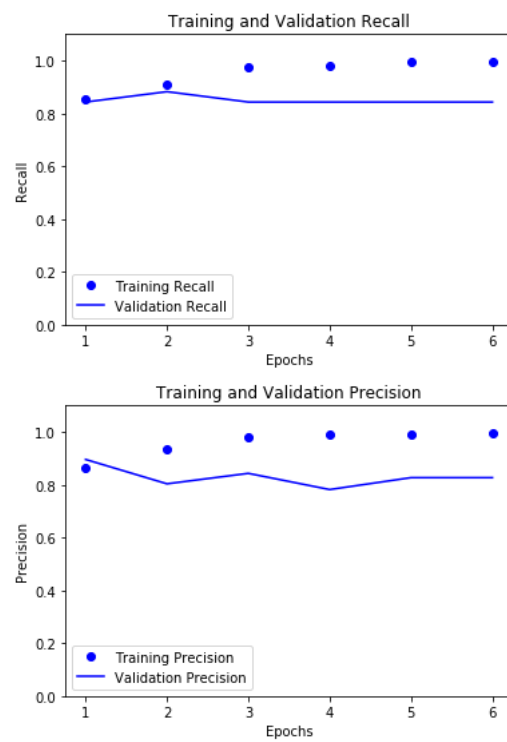
جستجوی دستی: برای شروع، یک لایه پنهان را امتحان می‌کنیم، زیرا اگر نورون‌های کافی به آنها داده شود، می‌تواند نتایج معقولی به همراه داشته باشد. با این حال، به دلیل داشتن کارایی پارامتر بالاتر، آموزش شبکه عمیق‌تر با نورون‌های کمتر سریع‌تر است. می‌توانیم به تدریج تعداد لایه‌های مخفی را افزایش دهیم تا زمانی که به مجموعه آموزشی اضافه شود [۱۷].

^{۲۴}Max-Norm

^{۲۵}Dropout



شکل ۱۵.۴: ارزیابی مدل توسط تابع زیان و درستی



شکل ۱۶.۴: ارزیابی مدل توسط تابع فراخوانی و دقت

در زیر ارزیابی مدل پرسپترون چندلایه و دقت آن را می‌بینیم:

Metric	Results
loss	0.011484
accuracy	0.997624
Recall	0.911504
Precision	0.980952

۷.۴ شبکه عصبی پیچشی

لایه‌های معمول در اینجا عبارتند از :

- Flatten() یک تنسور $(1, 20, 10, samples)$ را تبدیل به یک تنسور $(1 \times 20 \times 10, samples)$ می‌کند.


- GlobalAveragePooling2D() یا GlobalMaxPooling2D() یک تنسور $(2, 20, 1, samples)$ را تبدیل به یک تنسور $(2, 1, 1, samples)$ می‌کند [۹].

CNN سه‌بعدی: این نوع CNN دارای کرنلی است که در سه جهت حرکت می‌کند. محققان از این نوع CNN در تصاویر سه‌بعدی مانند سی‌تی‌اسکن و MRI استفاده می‌کنند. طراحی مدل: طرح‌های مدل زیادی برای CNN وجود دارد. برخی فقط از لایه‌هایی استفاده می‌کنند که قبلاً در مورد آنها صحبت کردیم، در حالی که برخی دیگر لایه‌های جدید را معرفی می‌کنند و از اتصالات صرف نظر می‌کنند. بیشتر این مدل‌ها بسیار «عمیق‌تر» (شامل لایه‌های بیشتری) از آنچه قبلاً ساخته‌ایم هستند. به این ترتیب، برای مدل‌های دوبعدی، ما باید کانال‌ها و سطوح الکتروود را به‌طور دور قرار دهیم تا لایه‌های مکس‌پولینگ^{۲۶} بیشتری را فراهم کنیم. همچنین، از آنجایی که آموزش مدل‌های عمیق بیشتر طول می‌کشد، برای اهداف نمایی، به جای وزن‌دهی کلاس، از یک مولد دسته‌ای متعادل استفاده می‌کنیم. به‌جای ساختن خودمان، از پکیج یادگیری نامتعادل استفاده خواهیم کرد. با این حال، این فقط داده‌های دوبعدی را می‌گیرد، بنابراین ابتدا باید داده‌های خود را تغییر شکل دهیم، آن‌ها را به ژنراتور دسته‌ای وارد کنیم و قبل از آموزش مدل، دوباره شکل دهیم. خوشبختانه به دست آوردن این خیلی سخت نیست. اجازه دهید اکنون داده‌های خود را تغییر شکل دهیم و اشیاء را با شکل ورودی و آنچه که می‌خواهیم آن‌ها را دوباره شکل دهیم، نگه داریم. مواردی از طراحی مدل در این روش نتوی‌جی‌جی^{۲۷}،

²⁶maxpooling

²⁷VGGNet

رزنت^{۲۸}، اکسپشن^{۲۹} و نت‌موج^{۳۰} هستند [۶].

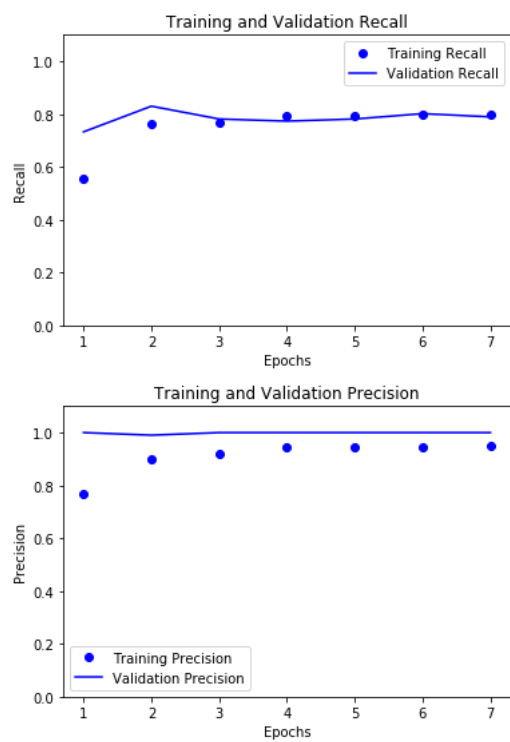


شکل ۱۷.۴: ارزیابی مدل توسط تابع زیان و درستی

²⁸ResNet

²⁹Xception

³⁰Wavenet



شکل ۱۸.۴: ارزیابی مدل توسط تابع فراخوانی و دقت

در زیر ارزیابی مدل شبکه عصبی پیچشی و دقت آن را می بینیم:

Metric	Results
loss	0.0696
accuracy	0.9885
Recall	0.9886
Precision	0.9886

۸.۴ مقایسه نتایج با کارهای قبلی

با توجه به رفرنس های ما، [۸] [۲۱] به نظر می آید که کار ارائه شده از دقت بهتری برخوردار است.

Threshold	0.4	0.6	0.4	0.6	0.4	0.6
Sensitivity	0.904	0.729	0.908	0.764	0.93	0.795
Precision	0.764	0.943	0.782	0.948	0.721	0.913
Accuracy	0.834	0.836	0.845	0.856	0.825	0.854
F1 score	0.845	0.817	0.854	0.841	0.842	0.845

شکل ۱۹.۴: ارزیابی مدل استفاده شده در مقاله مرجع

فصل ۵

جمع‌بندی

با توجه به اهمیتی که در قسمت‌های ابتدایی ذکر کردیم، تشخیص دقیق صرع می‌تواند از مشکلات عدیده‌ای جلوگیری کند. بررسی نوار مغزی به صورت انسانی می‌تواند کار سخت و زمان‌بری باشد؛ همچنین امکان خطای انسانی در آن وجود دارد. با دانستن این موضوع، بهترین راه برای نظارت و بررسی نوار مغزی EEG، استفاده از تکنولوژی و بالاخص، روش‌هایی مانند یادگیری ماشین و یادگیری عمیق است که عملاً کار انسانی را با دقت و سرعت بالاتر، اکثراً عاری از معایب آن، شبیه‌سازی می‌کند. در این پژوهش ما با دقت مناسبی روش‌های گفته‌شده را اجرا کرده و نتایج بهینه‌تری برای تشخیص حملات صرع از روی داده‌های ضبط‌شده، ارائه دادیم.

در این مسئله چالش‌هایی وجود داشتند که ابتدا باید آن‌ها را شناسایی و ترتیب‌بندی می‌دادیم. چندی از آنها عبارتند از:

تسلط بر این حوزه: دانش بر ویژگی‌های EEG می‌تواند بسیار به پی بردن اهمیت ویژگی‌های تاثیرگذار، کمک شایانی داشته باشد پس اولین چالش تسلط بر مفاهیم مرتبط با EEG و حملات صرع بود.

تعداد ناکافی داده‌های آموزشی: حتی ابتدایی‌ترین خطوط لوله یادگیری ماشینی می‌توانند در یک کار پیچیده به خوبی عمل کنند، اگر مقدار مناسب داده به آنها داده شود.

داده‌های آموزشی غیرقابل تعمیم: برای اینکه یک مدل به خوبی به داده‌های جدید تعمیم یابد، داده‌هایی که بر روی آن آموزش دیده‌اند باید معرف باشند. این را می‌توان با کمیت داده‌ها، به دلیل داشتن نمونه‌های کوچک که شانس بیشتری برای نویز دارند، و روش نمونه‌گیری ناقص، تحت تأثیر بایاس نمونه، تحت تأثیر قرار داد.

کیفیت داده ضعیف: همانطور که اغلب در مورد داده‌های دنیای واقعی اتفاق می‌افتد، پر از خطاها، نقاط پرت و نویز است که بر توانایی سیستم در تشخیص الگوها تأثیر می‌گذارد. سپس باید تصمیماتی اتخاذ شود که چگونه به این موارد رسیدگی شود، به عنوان مثال آیا مقادیر از دست رفته را نادیده می‌گیرید یا پر می‌کنید.

ویژگی‌های بی ربط: مهندسی ویژگی بخش مهمی از یک پروژه یادگیری ماشینی است زیرا تضمین می‌کند

که از ویژگی های مرتبط برای آموزش یک مدل استفاده می شود. علاوه بر ایجاد ویژگی ها، می توان آنها را برای سودمندی بیشتر انتخاب کرد یا با ترکیب کردن ویژگی ها برای ایجاد ویژگی های مفیدتر استخراج کرد.

تطبیق بیش از حد داده های آموزشی: مدل ها می توانند از داده هایی که روی آن ها آموزش دیده اند تعمیم بیشتری پیدا کنند، و گاهی اوقات روی الگوهایی تمرکز می کنند که فقط در داده های آموزشی دیده می شوند. این مدل برای داده ها بسیار پیچیده است و نیاز به ساده سازی دارد، اغلب با تغییر فرایارمترهای آن. عدم تناسب داده های آموزشی زمانی اتفاق می افتد که مدل خیلی ساده است و به مدل پیچیده تر، ویژگی های بهتر یا محدودیت های مدل کمتر نیاز دارد.

نحوه انتخاب مناسب ویژگی ها: انتخاب نامربوط یا زیاد از حد ویژگی ها، میتواند منجر به بیش برآزش و مشکلات عملکردی در مدل شود. همانطور که قبل تر هم گفته شد، برای حل این مشکل از PCA یا بررسی اهمیت ویژگی ها می توان استفاده کرد.

پیچیدگی های مدل ها: مدل هایی مانند شبکه عصبی پیچشی یا پرسپترون چندلایه میتوانند به دلیل پیچیدگی و حجم بالای هضم اطلاعات، دچار مشکلاتی مانند بیش برآزش شوند که با استفاده از روشهای گفته شده در فصل ۹ مانند dropout یا L_1 و L_2 استفاده کنیم تا از این امر جلوگیری شود.

در هر فصل، چالش های مرتبط بررسی شده اند و مثلاً قسمت هایی که در مورد کاهش ابعاد است، حتی بیشتر در بطن چالش ها به بررسی موارد می پردازد.

پژوهش های آینده: نتیجه گیری و دستورالعمل های آینده در مقالات بررسی شده، پیشرفت های ایجاد شده در تشخیص تشنج صرع با استفاده از سیگنال های EEG از طریق تکنیک های یادگیری عمیق و یادگیری ماشین را برجسته می کند. مطالعات مورد بحث پتانسیل این رویکردها را در تشخیص خودکار تشنج و بهبود مراقبت از بیمار نشان می دهد. با این حال، هنوز جا برای بهبود وجود دارد، به ویژه در پرداختن به چالش هایی مانند عدم تعادل کلاس، ناهمگونی دادگان، و اجرای بلادرنگ. تحقیقات آینده باید بر روی توسعه مدل های ترکیبی، ادغام روش های متعدد و کاوش در معماری های جدید برای افزایش دقت و کارایی سیستم های تشخیص تشنج متمرکز شود.

واژه‌نامه انگلیسی به فارسی

Accuracy	درستی
Activation Function	تابع فعال‌سازی
Artefacts	حالات (مصنوعی) غیرعادی
Artificial Intelligence	هوش مصنوعی
Artificial Neural Network	شبکه‌های عصبی مصنوعی
Backpropagation	پس‌انتشار خطا
Bayesian Algorithms	الگوریتم‌های بیزی
Biases	اریبی‌ها
Bias Neuron	نورون سوگیری
Classification Algorithms	الگوریتم‌های طبقه‌بندی
Clustering Algorithms	الگوریتم‌های خوشه‌بندی
Confusion Matrix	ماتریس درهم‌ریختگی
Cross-Validation	اعتبارسنجی متقاطع
Cutoff Frequency	فرکانس جداسازی
Dataset	دادگان
Deep Neural Networks	شبکه‌های عصبی عمیق
Elliptic	بیضوی
Encoder	کدگذار
Encoding	رمزگذاری
False negative rate	نرخ منفی کاذب
False positive rate	نرخ مثبت کاذب
F1-score	امتیاز یا معیار اف ۱
Fine-tune	تنظیم
False Positive Rate	نرخ مثبت کاذب
Generative Adversarial Networks	شبکه‌های مولد
Gradient Descent	کاهش گرادیان
Grid Search	جستجوی شبکه‌ای

Hyperplane	ابر صفحه
Ictal	اکتال
Inter-ictal	اینتر اکتال
Kernel	هسته
K-Fold Cross-Validation	اعتبارسنجی متقاطع کا-چین خورده
K-nearest neighbors	کا-نزدیکترین همسایه ها
Learning Algorithms	الگوریتم های یادگیری
Linear	خطی
Machine Learning	یادگیری ماشین
Margin Distance	فاصله حاشیه
MSE	تابع میانگین مربعات خطا
Naive	ساده
Naive Bayes Classifier	دسته بند بیز
Neural Networks	شبکه های عصبی
Objective Function	تابع هدف
Overfitting	بیش برازش
Precision	دقت پیش بینی
Precision-Recall Curve	منحنی دقت-فراخوانی
Radial Basis Function	تابع بر مبنای شعاع
Random Forest Algorithm	جنگل تصادفی
Recall	فراخوانی
Receiver Operating Characteristic plot	نمودار مشخصه عملکرد
Regression	رگرسیون
Regularization	منظم سازی
Shuffle	بر زدن
Sigmoid Function	تابع سیگموید
Standard Gold	بهترین روش
Stopband Attenuation	تضعیف باند توقف
Supervised Learning	یادگیری نظارت شده
Support Vector Machine	ماشین بردار پشتیبان
Task	مساله
Transformer	تبدیل کننده
True negative Rate	نرخ منفی صحیح
True Positive Rate	نرخ مثبت صحیح
t-Distributed Stochastic Neighbor	تی-توکاری همسایگی تصادفی توزیع شده
Embedding	
Underfitting	کم برازش

Unsupervised Learning.....	یادگیری نظارت نشده
Weights	وزن ها

واژه‌نامه فارسی به انگلیسی

Hyperplane	ابر صفحه
Biases	اریبی‌ها
Cross-Validation	اعتبارسنجی متقاطع
K-Fold Cross-Validation	اعتبارسنجی متقاطع کا-چین خورده
Ictal	اکتال
Bayesian Algorithms	الگوریتم‌های بیزی
Clustering Algorithms	الگوریتم‌های خوشه‌بندی
Classification Algorithms	الگوریتم‌های طبقه‌بندی
Learning Algorithms	الگوریتم‌های یادگیری
F1-score	امتیاز یا معیار اف ۱
Inter-ictal	اینتر اکتال
Shuffle	بر زدن
Standard Gold	بهترین روش
Overfitting	بیش‌برازش
Elliptic	بیضوی
Backpropagation	پس‌انتشار خطا
Radial Basis Function	تابع برمبنای شعاع
Sigmoid Function	تابع سیگموید
Activation Function	تابع فعال‌سازی
MSE	تابع میانگین مربعات خطا
Objective Function	تابع هدف
Transformer	تبدیل‌کننده
Stopband Attenuation	تضعیف باند توقف
Fine-tune	تنظیم
t-Distributed Stochastic Neighbor	تی-توکاری همسایگی تصادفی توزیع شده
Embedding	
Grid Search	جستجوی شبکه‌ای

Random Forest Algorithm	جنگل تصادفی
Artefacts	حالات (مصنوعی) غیرعادی
Linear	خطی
Dataset	دادگان
Accuracy	درستی
Naive Bayes Classifier	دسته‌بند بیز
Precision	دقت پیش‌بینی
Regression	رگرسیون
Encoding	رمزگذاری
Naive	ساده
Neural Networks	شبکه‌های عصبی
Deep Neural Networks	شبکه‌های عصبی عمیق
Artificial Neural Network	شبکه‌های عصبی مصنوعی
Generative Adversarial Networks	شبکه‌های مولد
Margin Distance	فاصله حاشیه
Recall	فراخوانی
Cutoff Frequency	فرکانس جداسازی
Gradient Descent	کاهش گرادیان
K-nearest neighbors	کا-نزدیکترین همسایه‌ها
Encoder	کدگذار
Underfitting	کم‌پرازش
Confusion Matrix	ماتریس درهم‌ریختگی
Support Vector Machine	ماشین بردار پشتیبان
Task	مساله
Precision-Recall Curve	منحنی دقت-فراخوانی
Regularization	منظم‌سازی
True Positive Rate	نرخ مثبت صحیح
False Positive Rate	نرخ مثبت کاذب
True negative Rate	نرخ منفی صحیح
False negative rate	نرخ منفی کاذب
Receiver Operating Characteristic plot	نمودار مشخصه عملکرد
Bias Neuron	نورون سوگیری
Weights	وزن‌ها
Kernel	هسته
Artificial Intelligence	هوش مصنوعی
Machine Learning	یادگیری ماشین
Supervised Learning	یادگیری نظارت شده

Unsupervised Learning..... یادگیری نظارت نشده

کتابنامه

- [1] Andrzejak, Ralph G, Lehnertz, Klaus, Mormann, Florian, Rieke, Christoph, David, Peter, and Elger, Christian E. Indications of non-linear deterministic and finite-dimensional structures in time series of brain electrical activity: Dependence on recording region and brain state. *Physical Review E*, 64(6):061907, 2001.
- [2] Baldassano, Steven N, Brinkmann, Benjamin H, Ung, Hoameng, Blevins, Tyler, Conrad, Erin C, Leyde, Kent, Cook, Mark J, Khambhati, Ankit N, Wagenaar, Joost B, Worrell, Gregory A, et al. Crowdsourcing seizure detection: algorithm development and validation on human implanted device recordings. *Brain*, 140(6):1680–1691, 2017.
- [3] Berg, Anne T. Risk of recurrence after a first unprovoked seizure. *Epilepsia*, 49:13–18, 2008.
- [4] Brinkmann, Benjamin H, Bower, Mark R, Stengel, Keith A, Worrell, Gregory A, and Stead, Matt. Large-scale electrophysiology: acquisition, compression, encryption, and storage of big data. *Journal of neuroscience methods*, 180(1):185–192, 2009.
- [5] Brodie, Martin J, Elder, Andrew T, and Kwan, Patrick. Epilepsy in later life. *The Lancet Neurology*, 8(11):1019–1030, 2009.
- [6] Chollet, Francois. The limitations of deep learning. *Deep learning with Python*, 2017.
- [7] Fisher, Robert S, Boas, Walter Van Emde, Blume, Warren, Elger, Christian, Genton, Pierre, Lee, Phillip, and Engel Jr, Jerome. Epileptic seizures and epilepsy: definitions proposed by the international league against epilepsy (ilae) and the international bureau for epilepsy (ibe). *Epilepsia*, 46(4):470–472, 2005.

- [8] Gabeff, Valentin, Teijeiro, Tomas, Zapater, Marina, Cammoun, Leila, Rheims, Sylvain, Rylvlin, Philippe, and Atienza, David. Interpreting deep learning models for epileptic seizure detection on eeg signals. *Artificial intelligence in medicine*, 117:102084, 2021.
- [9] Géron, Aurélien. *Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow*. " O'Reilly Media, Inc.", 2022.
- [10] Gotman, J_, Ives, JR, and Gloor, P. Frequency content of eeg and emg at seizure onset: possibility of removal of emg artefact by digital filtering. *Electroencephalography and clinical neurophysiology*, 52(6):626–639, 1981.
- [11] Hills, Michael. Seizure detection using fft, temporal and spectral correlation coefficients, eigenvalues and random forest. *Github, San Fr. CA, USA, Tech. Rep*, pages 1–10, 2014.
- [12] Hinton, Geoffrey E, Srivastava, Nitish, Krizhevsky, Alex, Sutskever, Ilya, and Salakhutdinov, Ruslan R. Improving neural networks by preventing co-adaptation of feature detectors. *arXiv preprint arXiv:1207.0580*, 2012.
- [13] Malow, Beth A. Sleep and epilepsy. *Neurologic clinics*, 23(4):1127–1147, 2005.
- [14] Michael, Glen E and O'Connor, Robert E. The diagnosis and management of seizures and status epilepticus in the prehospital setting. *Emergency Medicine Clinics*, 29(1):29–39, 2011.
- [15] Nair, Nadia R. A clinical introduction to epilepsy and the technological developments for detection and management of the condition.
- [16] Osorio, Ivan, Frei, Mark G, and Wilkinson, Steven B. Real-time automated detection and quantitative analysis of seizures and short-term prediction of clinical onset. *Epilepsia*, 39(6):615–627, 1998.
- [17] Raschka, Sebastian and Mirjalili, Vahid. Python machine learning: Machine learning and deep learning with python. *Scikit-Learn, and TensorFlow. Second edition ed*, 3, 2017.

- [18] Subasi, Abdulhamit, Kevric, Jasmin, and Abdullah Canbaz, M. Epileptic seizure detection using hybrid machine learning methods. *Neural Computing and Applications*, 31:317–325, 2019.
- [19] Thurman, David J, Beghi, Ettore, Begley, Charles E, Berg, Anne T, Buchhalter, Jeffrey R, Ding, Ding, Hesdorffer, Dale C, Hauser, W Allen, Kazis, Lewis, Kobau, Rosemarie, et al. Standards for epidemiologic studies and surveillance of epilepsy. *Epilepsia*, 52:2–26, 2011.
- [20] Truong, Nhan Duy, Kuhlmann, Levin, Bonyadi, Mohammad Reza, Yang, Jiawei, Faulks, Andrew, and Kavehei, Omid. Supervised learning in automatic channel selection for epileptic seizure detection. *Expert Systems with Applications*, 86:199–207, 2017.
- [21] Ullah, Ihsan, Hussain, Muhammad, Aboalsamh, Hatim, et al. An automated system for epilepsy detection using eeg brain signals based on deep learning approach. *Expert Systems with Applications*, 107:61–71, 2018.
- [22] Varsavsky, Andrea, Mareels, Iven, and Cook, Mark. *Epileptic seizures and the EEG: measurement, models, detection and prediction*. Taylor & Francis, 2011.
- [23] Wilden, Jessica A and Cohen-Gadol, Aaron A. Evaluation of first nonfebrile seizures. *American family physician*, 86(4):334–340, 2012.
- [24] Zheng, Alice and Casari, Amanda. *Feature engineering for machine learning: principles and techniques for data scientists*. ” O’Reilly Media, Inc.”, 2018.

Abstract

Epilepsy is a serious brain illness that is an endemic neurological disorder all over the world. It is a clinical result that occurs with abnormal neurological electrical discharging of the brain. Epileptic seizures represent the most common positive signs and symptoms of brain disturbance, and epilepsy is one of the most common primary brain disorders. Vascular causes, traumatic causes, infections and brain abscesses, brain tumors, nutritional deficiencies, pyridoxine deficiency, and calcium metabolism disorders are the leading causes of epilepsy. In diagnosing epilepsy, research is needed for a better understanding of the mechanisms causing epileptic disorders. The evaluation and treatment of neurophysiologic disorders are diagnosed with the electroencephalogram (EEG). EEG is crucial for the accurate classification of different forms of epilepsy and can provide us with invaluable information on detecting epileptic seizures.

The aim of this Research is to contribute to the diagnosis of epilepsy by taking advantage of artificial intelligence. This is obtained by diagnosing epilepsy using the most efficient machine learning and deep learning methods, performed on EEG recordings. Several machine learning methods are examined primarily, and then various deep learning methods are implemented on an appropriate dataset to achieve the best results.

Keywords: Artificial Intelligence, Machine Learning, Deep Learning, Epilepsy, seizure, Electroencephalography, brain injury



College of Science
School of Mathematics, Statistics, and Computer Science

Epileptic Seizure Detection By EEG Signals Using Deep Learning

Kimia Esmaili

Supervisor: Bagher Babaali

A thesis submitted in partial fulfillment of the requirements for
the degree of B.Sc. in Computer Science

2023